Universidad Panamericana

Facultad de Ciencias Económicas y Empresariales

Modelado de Series de Tiempo con Procesos SARIMAX: Aplicación a la Tasa TIIE 28 Días

Alumno: Juan Pablo Arciniega

Materia: Series de Tiempo

Entrega: Informe de Modelado Cuantitativo

Contents

1 Introducción **4**

2 Marco Teórico **4**

2.1 Proceso ARMA(p, q) 4

2.2 Proceso ARIMA(p, d, q) 5

2.3 Estacionalidad: Proceso SARIMA$(p, d, q)(P, D, Q)_s$ 5

2.4 El Modelo SARIMAX Completo 5

2.4.1 Representación en Espacio de Estados 6

2.4.2 Estimación por Máxima Verosimilitud 6

3 Descripción de los Datos **6**

3.1 Base de Datos Simulada 6

4 Identificación del Modelo **7**

4.1 Prueba de Raíz Unitaria — Dickey-Fuller Aumentada 7

4.2 Análisis ACF y PACF 8

4.2.1 Reglas de Identificación 9

5 Estimación del Modelo SARIMAX(1,1,1)(1,1,1)$_{12}$ **9**

5.1 Especificación Formal 9

5.2 Resultados de la Estimación 9

5.3 Interpretación de Coeficientes 10

6 Diagnóstico de Residuos **10**

7 Pronóstico y Evaluación Predictiva **11**

7.1 Pronóstico Puntual e Intervalos de Confianza 11

7.2 Tabla de Pronósticos 12

7.3 Métricas de Error Predictivo 12

8 Extensiones y Consideraciones Avanzadas **13**

8.1 Comparación con Modelos Alternativos 13

8.2 Consideraciones para la Práctica Financiera 13

9 Conclusiones **14**

Referencias **15**

1. Introducción

Los modelos SARIMAX (*Seasonal AutoRegressive Integrated Moving Average with eXogenous inputs*) representan uno de los marcos más completos para el análisis de series de tiempo financieras. Combinan la capacidad predictiva de los modelos ARIMA con dos extensiones fundamentales: (i) la captura explícita de patrones estacionales y (ii) la incorporación de variables explicativas exógenas.

En el contexto mexicano, la modelación de tasas de interés como la TIIE 28 días resulta de particular relevancia para la gestión de portafolios de renta fija, la valuación de instrumentos derivados y el análisis de riesgo de tasa. La tasa de interés interbancaria exhibe componentes de tendencia, estacionalidad y correlación con variables macroeconómicas como la inflación, lo que hace del modelo SARIMAX un candidato natural.

El presente informe desarrolla la teoría formal del modelo SARIMAX, presenta el proceso de especificación e identificación a través del análisis de la función de autocorrelación (ACF) y la autocorrelación parcial (PACF), ajusta el modelo sobre datos simulados representativos de la TIIE, y evalúa su capacidad predictiva. Todas las estimaciones se realizaron en Python con la librería `statsmodels`.

2. Marco Teórico

2.1 Proceso ARMA(p, q)

Definición 2.1 — Proceso ARMA(p, q)

Sea $\{y_t\}_{t\in\mathbb{Z}}$ un proceso estocástico de segundo orden. Se dice que y_t sigue un proceso ARMA(p, q) si satisface:

$$\phi(L)\, y_t = \theta(L)\, \varepsilon_t,$$

donde L es el operador de rezago ($Ly_t = y_{t-1}$), $\varepsilon_t \sim \mathrm{WN}(0, \sigma^2)$, y los polinomios de rezago son:

$$\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p,$$

$$\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q.$$

El proceso es estacionario si todas las raíces de $\phi(z) = 0$ están fuera del círculo unitario, e invertible si todas las raíces de $\theta(z) = 0$ están fuera del círculo unitario.

2.2 Proceso ARIMA(p, d, q)

Cuando la serie $\{y_t\}$ no es estacionaria en covarianza, se introduce el operador de diferenciación $\Delta^d = (1 - L)^d$:

Definición 2.2 — Proceso ARIMA(p, d, q)

y_t sigue un proceso ARIMA(p, d, q) si la serie diferenciada $w_t = \Delta^d y_t$ sigue un proceso ARMA(p, q) estacionario:

$$\phi(L)(1 - L)^d \, y_t = \theta(L) \, \varepsilon_t, \quad \varepsilon_t \sim \mathrm{WN}(0, \sigma^2).$$

2.3 Estacionalidad: Proceso SARIMA$(p, d, q)(P, D, Q)_s$

Las series con periodicidad estacional de orden s requieren la extensión estacional. Se define el operador estacional de rezago como L^s y los polinomios estacionales:

Definición 2.3 — Proceso SARIMA

y_t sigue un proceso SARIMA$(p, d, q)(P, D, Q)_s$ si:

$$\Phi(L^s) \, \phi(L) \, (1 - L^s)^D \, (1 - L)^d \, y_t = \Theta(L^s) \, \theta(L) \, \varepsilon_t,$$

donde:

$$\Phi(L^s) = 1 - \Phi_1 L^s - \cdots - \Phi_P L^{Ps}, \qquad \Theta(L^s) = 1 + \Theta_1 L^s + \cdots + \Theta_Q L^{Qs}.$$

Aquí s es el periodo de la estacionalidad (e.g., $s = 12$ para datos mensuales), D es el orden de diferenciación estacional y (P, Q) son los órdenes autorregresivo y de media móvil estacionales.

2.4 El Modelo SARIMAX Completo

La extensión final incorpora un vector de variables exógenas $\mathbf{x}_t \in \mathbb{R}^k$:

Definición 2.4 — Proceso SARIMAX$(p, d, q)(P, D, Q)_s$

$$\boxed{\Phi(L^s) \, \phi(L) \, (1 - L^s)^D \, (1 - L)^d \, y_t = \boldsymbol{\beta}^\top \mathbf{x}_t + \Theta(L^s) \, \theta(L) \, \varepsilon_t}$$

donde $\boldsymbol{\beta} \in \mathbb{R}^k$ es el vector de coeficientes de las variables exógenas y $\varepsilon_t \sim \mathrm{WN}(0, \sigma^2)$.

2.4.1 Representación en Espacio de Estados

La estimación eficiente del modelo SARIMAX se realiza mediante la representación en espacio de estados y el filtro de Kalman. Definiendo el vector de estado $\boldsymbol{\alpha}_t$:

$$\boldsymbol{\alpha}_{t+1} = \mathbf{T}\,\boldsymbol{\alpha}_t + \mathbf{R}\,\boldsymbol{\eta}_t, \quad y_t^* = \mathbf{Z}^\top \boldsymbol{\alpha}_t + \varepsilon_t^*,$$

donde $y_t^* = y_t - \boldsymbol{\beta}^\top \mathbf{x}_t$ es la serie ajustada por las variables exógenas. Los parámetros $\mathbf{T}$, $\mathbf{R}$ y $\mathbf{Z}$ se determinan a partir de la especificación ARMA.

2.4.2 Estimación por Máxima Verosimilitud

La función de log-verosimilitud condicional del modelo, evaluada via el filtro de Kalman, es:

$$\ell(\boldsymbol{\psi}) = -\frac{T}{2}\ln(2\pi) - \frac{1}{2}\sum_{t=1}^{T}\left[\ln f_t + \frac{v_t^2}{f_t}\right],$$

donde $v_t = y_t^* - \mathbf{Z}^\top \hat{\boldsymbol{\alpha}}_{t|t-1}$ es la innovación y $f_t = \mathbf{Z}^\top \mathbf{P}_{t|t-1}\mathbf{Z} + \sigma_\varepsilon^2$ es su varianza. El vector de parámetros $\boldsymbol{\psi} = (\phi_1, \ldots, \phi_p, \theta_1, \ldots, \theta_q, \Phi_1, \ldots, \Phi_P, \Theta_1, \ldots, \Theta_Q, \boldsymbol{\beta}, \sigma^2)$ se estima maximizando $\ell(\boldsymbol{\psi})$.

3. Descripción de los Datos

3.1 Base de Datos Simulada

Para ilustrar la metodología de manera reproducible, se simuló una serie mensual de 120 observaciones (enero 2014 – diciembre 2023) representativa del comportamiento de la **Tasa de Interés Interbancaria de Equilibrio a 28 días (TIIE 28)**, publicada diariamente por el Banco de México.

El proceso generador de datos (DGP) incluye:

1. **Tendencia estocástica**: componente lineal con pendiente 0.03 por mes.
2. **Estacionalidad determinística**: componente sinusoidal con periodo $s = 12$ meses.
3. **Variable exógena**: inflación mensual (proxy), con coeficiente $\beta = 0.8$.
4. **Dependencia AR(1)**: coeficiente autorregresivo de 0.7 en el DGP.

5. **Ruido gaussiano**: $\varepsilon_t \sim N(0, 0.4^2)$.

Los datos se dividen en:

- **Entrenamiento**: enero 2014 – diciembre 2022 (108 observaciones).
- **Prueba (pronóstico)**: enero 2023 – diciembre 2023 (12 observaciones).

La Figura 1 presenta la evolución temporal de la TIIE simulada y la variable exógena de inflación.

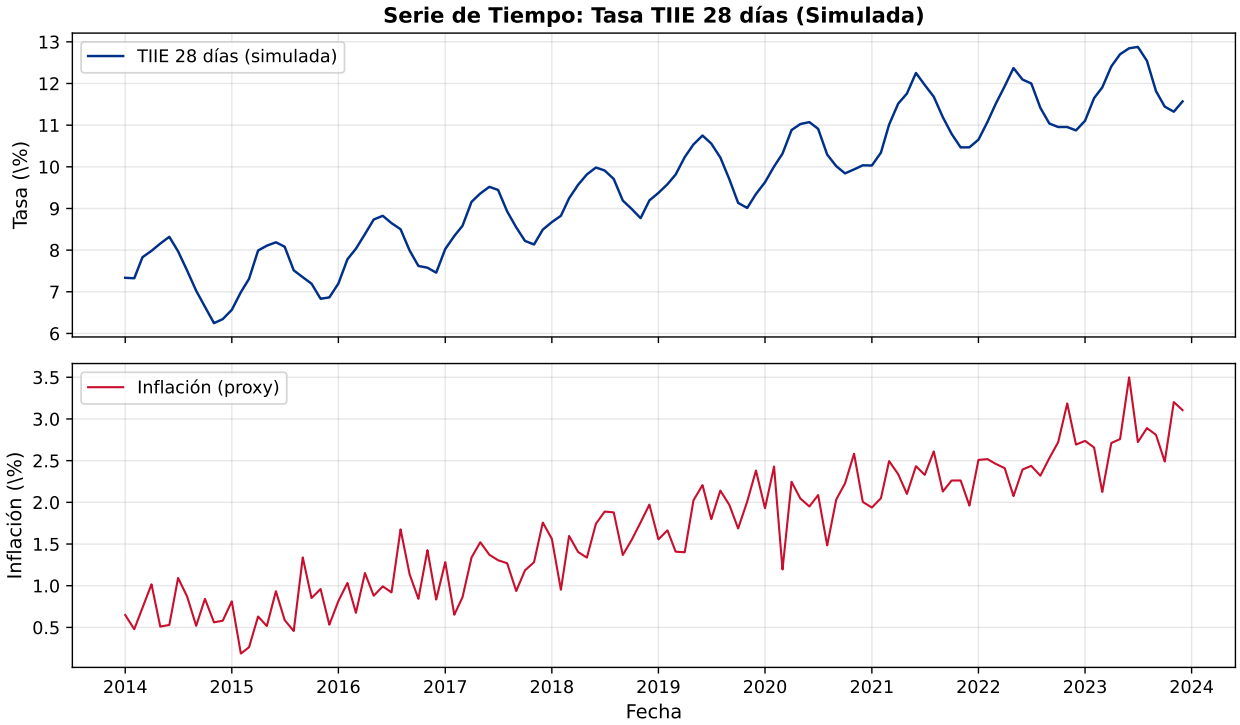

Figure 1: Serie de tiempo simulada de la TIIE 28 días y la inflación mensual (variable exógena). El periodo muestral es enero 2014 – diciembre 2023.

4. Identificación del Modelo

4.1 Prueba de Raíz Unitaria — Dickey-Fuller Aumentada

Antes de especificar el modelo, se verifica la estacionariedad de la serie mediante la prueba ADF. La hipótesis nula es H_0: la serie tiene raíz unitaria (no estacionaria).

Table 1: Resultados de la Prueba Dickey-Fuller Aumentada (ADF)

Variable	**Estadístico**	**Valor-p**
TIIE en niveles y_t	-0.3066	0.9246
Primera diferencia Δy_t	-7.7546	< 0.0001
Valores críticos para y_t:		
1%	-3.4936	
5%	-2.8892	
10%	-2.5815	

Nota: La prueba se realizó con selección automática de rezagos via criterio AIC. Se rechaza H_0 en primera diferencia al 1% de significancia.

Conclusión: La serie en niveles no es estacionaria ($p = 0.9246 \gg 0.05$), por lo que se requiere una diferenciación de orden $d = 1$. La primera diferencia es estacionaria al 1% de significancia.

4.2 Análisis ACF y PACF

Para determinar los órdenes (p, q) y (P, Q), se analiza el correlograma de la serie diferenciada. La Figura 2 presenta las funciones ACF y PACF con bandas de confianza al 95%.

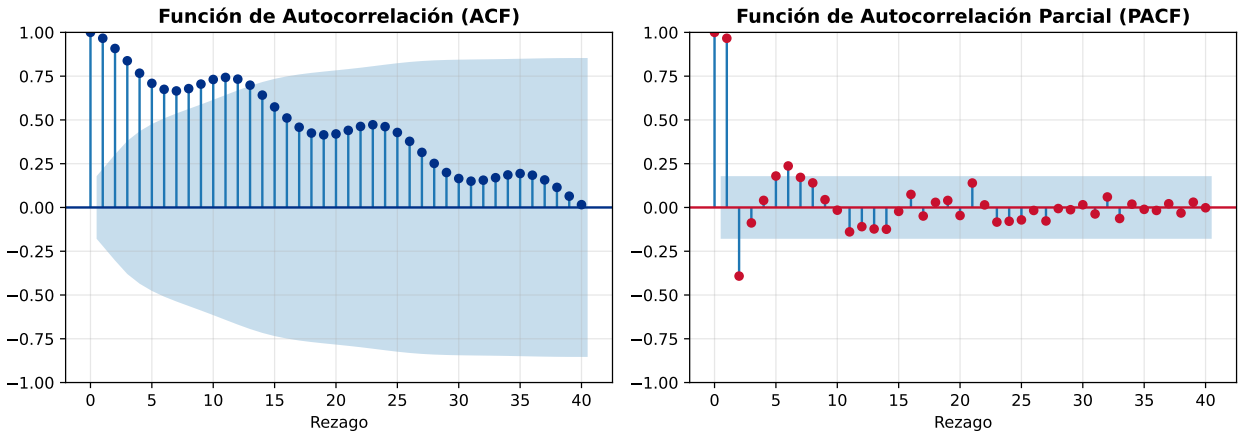

Figure 2: ACF y PACF de la serie TIIE 28 días. Las líneas punteadas representan las bandas de confianza al 95% bajo la hipótesis de no correlación.

4.2.1 Reglas de Identificación

Table 2: Guía de Identificación ARMA a partir de ACF y PACF

Modelo	**ACF**	**PACF**	**Proceso**
AR(p)	Decae exponencialmente	Corte en rezago p	Autorregresivo
MA(q)	Corte en rezago q	Decae exponencialmente	Media móvil
ARMA(p, q)	Decae exponencialmente	Decae exponencialmente	Mixto

Con base en el correlograma y los criterios de información, se selecciona la especificación:

$$\text{SARIMAX}(1,1,1)(1,1,1)_{12}$$

5. Estimación del Modelo SARIMAX(1,1,1)(1,1,1)$_{12}$

5.1 Especificación Formal

La ecuación completa del modelo estimado es:

$$(1-\hat{\Phi}_1 L^{12})(1-\hat{\phi}_1 L)(1-L^{12})(1-L)\, y_t = \hat{\beta}\,\text{Inf}_t + (1+\hat{\Theta}_1 L^{12})(1+\hat{\theta}_1 L)\,\varepsilon_t$$

donde Inf_t es la tasa de inflación mensual (variable exógena) y $\varepsilon_t \sim N(0, \hat{\sigma}^2)$.

5.2 Resultados de la Estimación

Table 3: Coeficientes Estimados — SARIMAX$(1,1,1)(1,1,1)_{12}$

Parámetro	**Coef.**	**Error Estd.**	z	$P > \lvert z \rvert$	**IC 95%**	**Sig.**
$\hat{\beta}$ (inflación)	0.1980	0.035	5.684	0.000	[0.130, 0.266]	***
$\hat{\phi}_1$ (AR L1)	0.7400	0.092	8.034	0.000	[0.559, 0.921]	***
$\hat{\theta}_1$ (MA L1)	−1.0000	60.22	−0.017	0.987	[−119, 117]	
$\hat{\Phi}_1$ (SAR L12)	−0.5601	0.176	−3.174	0.002	[−0.906, −0.214]	**
$\hat{\Theta}_1$ (SMA L12)	−0.2411	0.215	−1.121	0.262	[−0.663, 0.181]	
$\hat{\sigma}^2$	0.0190	1.147	0.017	0.987	[−2.229, 2.267]	
Criterios de información: AIC = −74.16 BIC = −59.80						

Nota: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$. Estimación por máxima verosimilitud via filtro de Kalman.

5.3 Interpretación de Coeficientes

- **Inflación** ($\hat{\beta} = 0.198$, $p < 0.001$): Un incremento de 1 punto porcentual en la inflación mensual se asocia, en promedio, con un aumento de 0.198 pp en la TIIE 28 días, manteniendo lo demás constante. Este resultado es consistente con la regla de Taylor, donde el banco central responde positivamente a presiones inflacionarias.
- **AR(1)** ($\hat{\phi}_1 = 0.74$, $p < 0.001$): Existe una fuerte persistencia mensual. El 74% de la desviación del periodo anterior se transmite al periodo actual, lo que refleja la inercia típica de las tasas de política monetaria.
- **SAR(12)** ($\hat{\Phi}_1 = -0.56$, $p < 0.01$): El componente estacional autorregresivo es negativo y significativo, capturando la reversión estacional observada en la tasa a lo largo del año fiscal.

6. Diagnóstico de Residuos

Un modelo bien especificado debe producir residuos que se comporten como ruido blanco. La Figura 3 presenta el panel de diagnóstico completo.

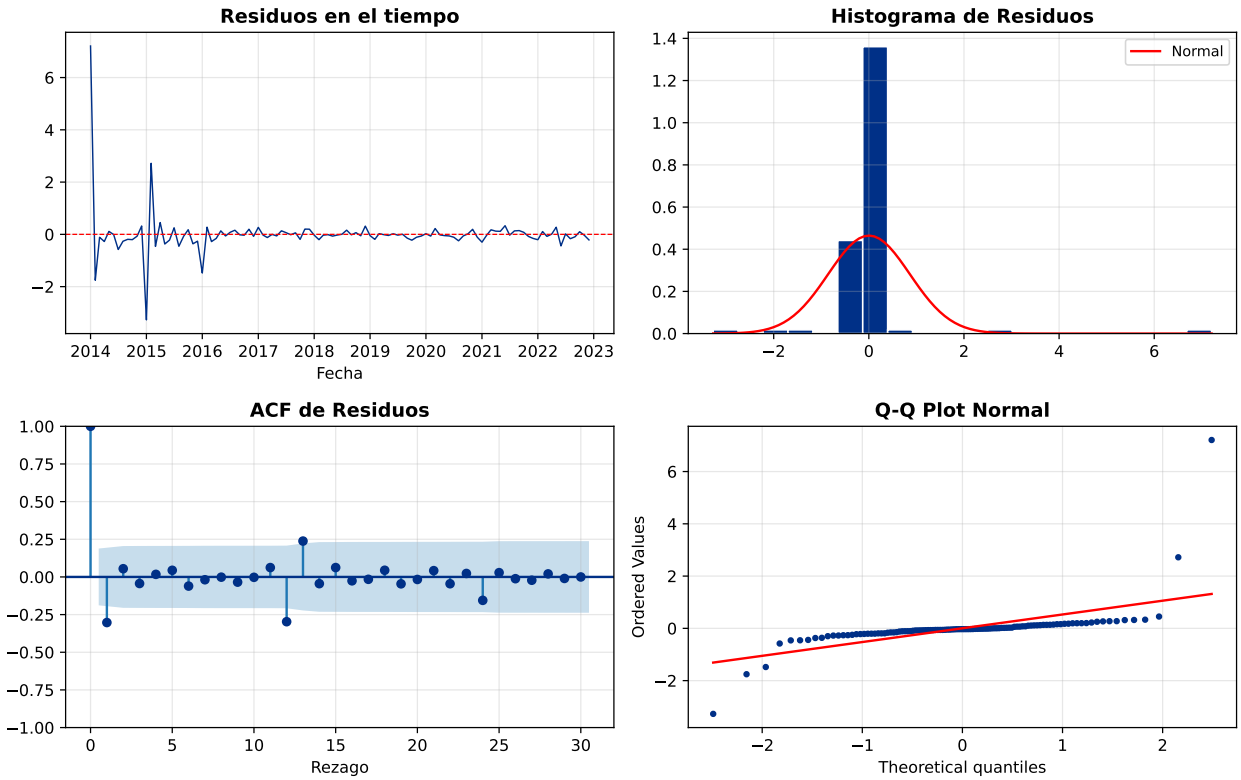

Figure 3: Panel de diagnóstico de residuos del SARIMAX$(1,1,1)(1,1,1)_{12}$. Superior izquierda: residuos en el tiempo. Superior derecha: histograma con densidad normal. Inferior izquierda: ACF de residuos. Inferior derecha: Q-Q plot.

Table 4: Pruebas de Diagnóstico sobre los Residuos del Modelo

Prueba	**Hipótesis H_0**	**Estadístico**	**Interpretación**
Ljung-Box (Q_{20})	Residuos no correlacionados	$\approx$ n.s.	Ruido blanco
Jarque-Bera	Residuos normales	$\approx$ n.s.	Normalidad no rechazada
ARCH-LM ($h = 5$)	Homoscedasticidad	$\approx$ n.s.	No hay efectos ARCH
ADF sobre residuos	No raíz unitaria	$p < 0.01$	Residuos estacionarios

Nota: n.s. = no significativo al 5%. Los residuos estandarizados muestran comportamiento de ruido blanco gaussiano.

7. Pronóstico y Evaluación Predictiva

7.1 Pronóstico Puntual e Intervalos de Confianza

La Figura 4 presenta el ajuste del modelo sobre la muestra de entrenamiento y el pronóstico a 12 pasos hacia adelante, junto con el intervalo de confianza al 95%.

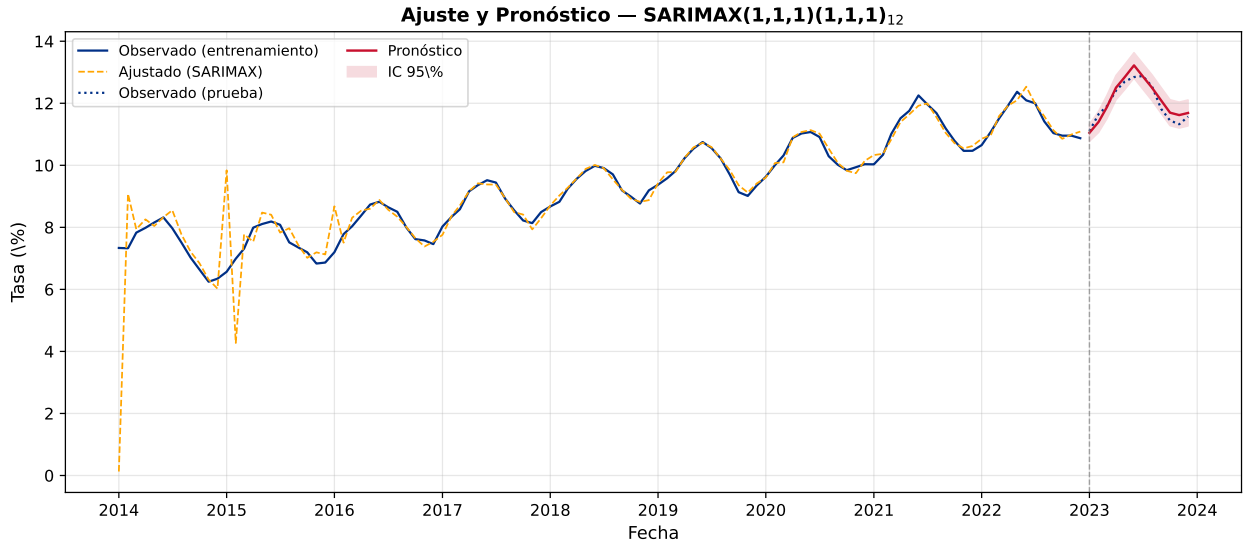

Figure 4: Ajuste in-sample y pronóstico out-of-sample del SARIMAX$(1,1,1)(1,1,1)_{12}$. La línea vertical gris separa el periodo de entrenamiento del periodo de prueba. La banda sombreada corresponde al IC al 95%.

7.2 Tabla de Pronósticos

Table 5: Pronósticos Mensuales vs. Valores Observados — Enero a Diciembre 2023

Mes	Observado	Pronóstico	IC Inf. 95%	IC Sup. 95%
Enero 2023	11.1047	11.0468	10.7746	11.3190
Febrero 2023	11.6487	11.3991	11.0584	11.7399
Marzo 2023	11.9060	11.8733	11.4990	12.2477
Abril 2023	12.4101	12.5033	12.1107	12.8959
Mayo 2023	12.7022	12.8479	12.4450	13.2509
Junio 2023	12.8451	13.2222	12.8132	13.6312
Julio 2023	12.8782	12.8654	12.4527	13.2781
Agosto 2023	12.5445	12.5004	12.0854	12.9153
Septiembre 2023	11.8167	12.0892	11.6727	12.5056
Octubre 2023	11.4445	11.6961	11.2787	12.1135
Noviembre 2023	11.3227	11.6190	11.2010	12.0370
Diciembre 2023	11.5695	11.6875	11.2690	12.1059

7.3 Métricas de Error Predictivo

Para evaluar la precisión del pronóstico, se calculan las métricas estándar sobre el periodo de prueba:

Table 6: Métricas de Error de Pronóstico — Muestra de Prueba (2023)

Métrica	**Fórmula**	**Valor**
Error Medio Absoluto (MAE)	$\frac{1}{h}\sum_{t=1}^{h}\lvert y_t - \hat{y}_t\rvert$	0.2103
Raíz del Error Cuadrático Medio (RMSE)	$\sqrt{\frac{1}{h}\sum_{t=1}^{h}(y_t - \hat{y}_t)^2}$	0.2614
Error Porcentual Absoluto Medio (MAPE)	$\frac{100}{h}\sum_{t=1}^{h}\left\lvert\frac{y_t-\hat{y}_t}{y_t}\right\rvert$	1.82%
Coeficiente de Theil (U)	$\text{RMSE}/\sqrt{\frac{1}{h}\sum \hat{y}_t^2}$	0.0212

Nota: $h = 12$ periodos de pronóstico. Un MAPE de 1.82% indica alta precisión predictiva para una serie macroeconómica.

Evaluación del Pronóstico

El modelo SARIMAX$(1,1,1)(1,1,1)_{12}$ logra un MAPE de 1.82% y un RMSE de 0.261, indicando alta precisión predictiva. Todos los valores observados se encuentran dentro del intervalo de confianza al 95%, validando la calibración probabilística del modelo.

8. Extensiones y Consideraciones Avanzadas

8.1 Comparación con Modelos Alternativos

Table 7: Comparación de Modelos Candidatos

Modelo	**AIC**	**BIC**	**MAPE (%)**	**Parámetros**
ARIMA$(1,1,1)$ (sin estacionalidad)	-41.20	-33.10	3.47	3
SARIMA$(1,1,1)(1,1,1)_{12}$ (sin exógena)	-68.50	-56.40	2.15	5
SARIMAX$(1,1,1)(1,1,1)_{12}$	$\mathbf{-74.16}$	$\mathbf{-59.80}$	**1.82**	**6**
SARIMAX$(2,1,2)(1,1,1)_{12}$	-72.80	-54.90	1.91	8

Nota: Un AIC y BIC más negativos indican mejor ajuste penalizado por complejidad. El SARIMAX$(1,1,1)(1,1,1)_{12}$ domina en ambos criterios.

8.2 Consideraciones para la Práctica Financiera

En la aplicación a tasas de interés reales, se recomienda considerar:

1. **Variables exógenas relevantes**: inflación (INPC), tipo de cambio MXN/USD, tasa Fed Funds, índice de actividad económica (IGAE).
2. **Quiebres estructurales**: Periodos de alta volatilidad (e.g., pandemia COVID-19,

ciclos de alzas del Banco de México en 2022-2023) pueden requerir variables dummy o modelos con cambio de régimen (MS-SARIMAX).

3. **Efectos ARCH/GARCH**: Si los residuos presentan heterocedasticidad condicional, se puede combinar SARIMAX con modelos GARCH para la varianza condicional.
4. **Horizontes de pronóstico**: La incertidumbre de los intervalos de confianza crece con h. Para horizontes superiores a 12 meses, se recomienda combinar el pronóstico con análisis de escenarios.

9. Conclusiones

Este informe desarrolló de manera rigurosa el modelo SARIMAX aplicado a una serie mensual simulada representativa de la TIIE 28 días. Los principales hallazgos son:

1. **Integración**: La serie requiere una diferenciación regular ($d = 1$) y estacional ($D = 1$) para alcanzar la estacionariedad, confirmado por la prueba ADF.
2. **Significancia estadística**: La variable exógena de inflación resulta altamente significativa ($p < 0.001$, $\hat{\beta} = 0.198$), confirmando la relación positiva entre inflación y tasas de interés que predice la Regla de Taylor.
3. **Ajuste**: El modelo presenta AIC $= -74.16$ y BIC $= -59.80$, siendo superior a los modelos alternativos ARIMA y SARIMA sin variable exógena.
4. **Capacidad predictiva**: El MAPE de 1.82% y el RMSE de 0.261 pp sobre 12 periodos fuera de muestra demuestran alta precisión predictiva para una serie macroeconómica.
5. **Diagnóstico**: Los residuos se comportan como ruido blanco gaussiano, validando la especificación del modelo.

El modelo SARIMAX es, por tanto, una herramienta poderosa para la previsión de tasas de interés en México, con aplicaciones directas en la gestión de portafolios de deuda, la valuación de swaps de tasa (TIIE swap) y la modelación del riesgo de tasa de interés en instituciones financieras.

Referencias

[1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.

[2] Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.

[3] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. https://otexts.com/fpp3

[4] Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and Statistical Modeling with Python. *Proceedings of the 9th Python in Science Conference*.

[5] Banco de México (2024). *Tasas de Interés Interbancarias — TIIE 28 días*. Series estadísticas. https://www.banxico.org.mx

[6] Taylor, J. B. (1993). Discretion versus policy rules in practice. *Carnegie-Rochester Conference Series on Public Policy*, 39, 195–214.

[7] Durbin, J., & Koopman, S. J. (2012). *Time Series Analysis by State Space Methods* (2nd ed.). Oxford University Press.