

UNIVERSIDAD PANAMERICANA

Facultad de Ciencias Empresariales

Series de Tiempo para Finanzas

ARIMA · SARIMA · SARIMAX · Pronóstico

Dr. César Galindo | Verano 2026

Alumno: Juan Pablo Arciniega

SECCIÓN 1 — Procesos Estacionarios y Fundamentos

Ejercicio 1.1 — Estacionariedad, ACF y PACF

(a) Estacionariedad débil vs. estricta

Estacionariedad débil (de covarianza). Un proceso $\{Y_t\}$ es débilmente estacionario si: (i) su media es constante $E[Y_t] = \mu$ para todo t ; (ii) su función de autocovarianza $\gamma(k) = \text{Cov}(Y_t, Y_{t-k})$ depende únicamente del rezago k y no de t .

Estacionariedad estricta. La distribución conjunta de $(Y_{t_1}, \dots, Y_{t_m})$ es idéntica a la de $(Y_{t_1+h}, \dots, Y_{t_m+h})$ para todo h y cualquier elección de índices. Implica débil si el segundo momento es finito.

Ejemplo: Sea $Y_t = \varepsilon_t$ con $\varepsilon_t \sim t(v)$ i.i.d., $v > 2$. Entonces $E[Y_t] = 0$ y $\text{Cov}(Y_t, Y_{t-k}) = 0$ para $k \neq 0$ (débilmente estacionario). Sin embargo, si transformamos linealmente sus momentos, la distribución marginal cambia al variar v — un proceso con $\varepsilon_t \sim t(3)$ mezclado aleatoriamente no sería estrictamente estacionario. Un ejemplo canónico más directo: tome $Y_t = Z$ donde $Z \sim N(0,1)$ es fija para todo t . Es débilmente estacionario (constante) pero no estrictamente porque la distribución conjunta de (Y_1, Y_2) es colineal, algo que no ocurriría con ruido blanco i.i.d.

(b) Prueba: $|\rho(k)| \leq 1$ y $\rho(k) = \rho(-k)$

Simetría: $\rho(k) = \gamma(k)/\gamma(0) = \text{Cov}(Y_t, Y_{t-k})/\text{Var}(Y_t)$. Por la simetría de la covarianza $\text{Cov}(Y_t, Y_{t-k}) = \text{Cov}(Y_{t-k}, Y_t) = \gamma(-k)$, de donde $\rho(k) = \rho(-k)$. ■

Cota: Por la desigualdad de Cauchy-Schwarz, $|\text{Cov}(Y_t, Y_{t-k})| \leq \sqrt{\text{Var}(Y_t)} \cdot \sqrt{\text{Var}(Y_{t-k})}$. Dado que el proceso es estacionario, $\text{Var}(Y_t) = \text{Var}(Y_{t-k}) = \gamma(0)$. Entonces $|\gamma(k)| \leq \gamma(0)$, lo que implica $|\rho(k)| = |\gamma(k)|/\gamma(0) \leq 1$. ■

(c) AR(1): Var, Cov y $\rho(k) = 0.6^{|k|}$

Sea $Y_t = 0.6 Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \sim \text{WN}(0, \sigma^2)$ y $|0.6| < 1$.

Varianza: Tomando varianzas en la ecuación del AR(1): $\text{Var}(Y_t) = 0.36 \text{Var}(Y_{t-1}) + \sigma^2$. Por estacionariedad $\text{Var}(Y_t) = \text{Var}(Y_{t-1}) = \gamma(0)$, por lo que $\gamma(0) = \sigma^2/(1 - 0.36) = \sigma^2/0.64$.

Autocovarianza a rezago 1: $\text{Cov}(Y_t, Y_{t-1}) = \text{Cov}(0.6 Y_{t-1} + \varepsilon_t, Y_{t-1}) = 0.6 \text{Var}(Y_{t-1}) = 0.6 \gamma(0)$. Luego $\rho(1) = 0.6$.

Estructura de decaimiento: Multiplicando la ecuación del AR(1) por Y_{t-k} y tomando esperanzas: $\gamma(k) = 0.6 \gamma(k-1)$ para $k \geq 1$. Esto implica $\gamma(k) = 0.6^k \gamma(0)$, y por tanto $\rho(k) = 0.6^k$ para $k \geq 0$. ■

(d) Patrones ACF y PACF

AR(1) con $\phi > 0$: La ACF decae exponencialmente: $\rho(k) = \phi^k \rightarrow 0$. La PACF tiene un único pico significativo en $k = 1$ y es prácticamente cero para $k \geq 2$. El corte abrupto de la PACF revela el orden $p = 1$.

MA(1) con $\theta > 0$: La ACF tiene un único pico significativo en $k = 1$ [$\rho(1) = \theta/(1+\theta^2)$] y es exactamente cero para $k \geq 2$. La PACF decae exponencialmente. El corte abrupto de la ACF revela el orden $q = 1$.

Ruido blanco: ACF y PACF son estadísticamente cero para todos los rezagos $k \geq 1$. Las autocorrelaciones muestrales siguen $N(0, 1/T)$ bajo H_0 .

Utilidad para identificación: cada tipo de modelo produce una firma característica en ACF/PACF. El investigador contrasta el patrón observado contra las tres plantillas para determinar los órdenes p y q antes de estimar los parámetros.

Ejercicio 1.2 — Procesos AR, MA y ARMA

(a) AR(2): raíces de $\Phi(z)$

El modelo es $Y_t = 1.2 Y_{t-1} - 0.32 Y_{t-2} + \varepsilon_t$. El polinomio autorregresivo es:

$$\Phi(z) = 1 - 1.2z + 0.32z^2$$

Aplicando la fórmula cuadrática: $z = [1.2 \pm \sqrt{(1.44 - 4 \times 0.32)}] / (2 \times 0.32) = [1.2 \pm \sqrt{(1.44 - 1.28)}] / 0.64 = [1.2 \pm \sqrt{0.16}] / 0.64 = [1.2 \pm 0.4] / 0.64$.

Raíz 1: $z_1 = 1.6/0.64 = 2.5$. Raíz 2: $z_2 = 0.8/0.64 = 1.25$.

Ambas raíces tienen módulo mayor que 1 ($|z_1| = 2.5 > 1$ y $|z_2| = 1.25 > 1$), por lo que se encuentran fuera del círculo unitario. El proceso AR(2) es estacionario.

(b) MA(2): varianzas y covarianzas

Sea $Y_t = \varepsilon_t + 0.5 \varepsilon_{t-1} - 0.3 \varepsilon_{t-2}$, con $\varepsilon_t \sim WN(0, \sigma^2)$.

$$\text{Var}(Y_t) = (1 + 0.5^2 + 0.3^2) \sigma^2 = (1 + 0.25 + 0.09) \sigma^2 = 1.34 \sigma^2$$

$$\text{Cov}(Y_t, Y_{t-1}) = (0.5 \times 1 + (-0.3) \times 0.5) \sigma^2 = (0.5 - 0.15) \sigma^2 = 0.35 \sigma^2$$

$$\text{Cov}(Y_t, Y_{t-2}) = (-0.3 \times 1) \sigma^2 = -0.3 \sigma^2$$

$\text{Cov}(Y_t, Y_{t-k}) = 0$ para $k \geq 3$, porque los pesos MA no se superponen más allá del orden $q = 2$.

(c) Invertibilidad de un MA(q)

Un MA(q) es invertible si todas las raíces del polinomio de medias móviles $\Theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q$ se ubican fuera del círculo unitario, es decir, $|z_j| > 1$ para todo j .

Importancia para el pronóstico: la invertibilidad garantiza que el proceso admite una representación AR(∞) convergente: $\varepsilon_t = Y_t + \pi_1 Y_{t-1} + \pi_2 Y_{t-2} + \dots$. Esto permite expresar el error actual como función del historial observable, lo que es indispensable para construir pronósticos de mínimo error cuadrático medio. Sin invertibilidad, los pronósticos serían inestables e irrealizables.

(d) Representación MA(∞) del AR(1) estacionario

Sea $Y_t = \phi Y_{t-1} + \varepsilon_t$ con $|\phi| < 1$. Sustituyendo recursivamente:

$$\begin{aligned} Y_t &= \varepsilon_t + \phi Y_{t-1} = \varepsilon_t + \phi(\varepsilon_{t-1} + \phi Y_{t-2}) = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 Y_{t-2} \\ &= \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \phi^3 Y_{t-3} = \dots = \sum_{j=0}^N \phi^j \varepsilon_{t-j} + \phi^{N+1} Y_{t-N-1}. \end{aligned}$$

Cuando $N \rightarrow \infty$, el término $\phi^{N+1} Y_{t-N-1} \rightarrow 0$ en media cuadrática porque $|\phi| < 1$ y $\text{Var}(Y_{t-N-1}) = \gamma(0) < \infty$. Por lo tanto: $Y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$. ■

Ejercicio 1.3 — Raíces unitarias y prueba de Dickey-Fuller

(a) No estacionariedad de la caminata aleatoria

Sea $Y_t = Y_{t-1} + \varepsilon_t$ con $Y_0 = 0$. Entonces $Y_t = \sum_{s=1}^t \varepsilon_s$.

$\text{Var}(Y_t) = \text{Var}(\sum_{s=1}^t \varepsilon_s) = t \sigma^2$, que crece sin límite con t . Un proceso estacionario requiere varianza finita y constante: la caminata aleatoria viola ambas condiciones.

Covarianza: $\text{Cov}(Y_t, Y_s) = \text{Cov}(\sum_{r=1}^t \varepsilon_r, \sum_{r=1}^s \varepsilon_r) = \min(s, t) \sigma^2$, que depende de los tiempos t y s , no sólo del rezago $|t - s|$. ■

(b) Primera diferencia de la caminata aleatoria

$$\Delta Y_t = Y_t - Y_{t-1} = (Y_{t-1} + \varepsilon_t) - Y_{t-1} = \varepsilon_t \sim \text{WN}(0, \sigma^2).$$

La primera diferencia es ruido blanco, un proceso estacionario. Esto confirma que la caminata aleatoria es integrada de orden 1, $I(1)$.

(c) Distribución no estándar bajo H_0 en la prueba ADF

Bajo H_0 : $\delta = 0$ en $\Delta Y_t = \mu + \delta Y_{t-1} + \sum_j \psi_j \Delta Y_{t-j} + \varepsilon_t$, el regresor Y_{t-1} no es estacionario. En particular, $Y_{t-1} \approx \sigma \cdot W(t)$, donde $W(\cdot)$ es un proceso de Wiener. El estadístico de δ no sigue la distribución t-student de Student porque los regresores no son independientes del término de error y divergen al infinito. La distribución límite correcta está dada por funcionales del movimiento browniano estándar (distribución de Dickey-Fuller), que tiene colas más pesadas que la t . Usar cuantiles t estándar provocaría rechazar H_0 con mayor frecuencia de la nominal.

(d) Series $I(1)$ vs $I(0)$ en finanzas

Los log-precios $P_t = \log(S_t)$ son típicamente $I(1)$: tienen varianza que crece con el tiempo, tendencia estocástica y no tienen nivel de reversión. Son, esencialmente, caminatas aleatorias.

Los log-retornos $r_t = \Delta P_t = \log(S_t/S_{t-1})$ son $I(0)$: estacionarios, con media y varianza finitas y constantes.

Implicación para modelado: no se debe aplicar regresión directa entre dos series $I(1)$ sin verificar cointegración (riesgo de regresión espuria). El modelado de volatilidad, predicciones de corto plazo y pruebas de hipótesis se realizan sobre los retornos $I(0)$. Para predicción de niveles a largo plazo, se necesita integrar las predicciones de retornos.

SECCIÓN 2 — Modelos ARIMA(p, d, q)

Ejercicio 2.1 — Identificación, estimación y diagnóstico

(a) Patrones ACF/PACF e identificación del modelo

(i) **ACF decae exponencialmente; PACF se corta en rezago 2:** Sugiere AR(2). La PACF con corte abrupto en el orden p identifica el componente autorregresivo.

(ii) **ACF se corta en rezago 1; PACF decae exponencialmente:** Sugiere MA(1). El corte abrupto de la ACF en el orden q identifica el componente de medias móviles.

(iii) **Ambas ACF y PACF decaen sin cortarse:** Sugiere ARMA(p, q) con $p \geq 1$ y $q \geq 1$. Ninguna exhibe el corte característico de un proceso puro AR o MA.

(iv) **ACF con pico significativo sólo en rezago 1, cero después:** Sugiere MA(1). Es el caso de corte abrupto de la ACF en $q = 1$.

(b) Criterios AIC y BIC

AIC = $-2 \log \hat{L} + 2k$. Penaliza cada parámetro adicional con 2 unidades. Tiende a seleccionar modelos más complejos, especialmente con muestras grandes.

BIC = $-2 \log \hat{L} + k \log n$. La penalidad por parámetro es $\log n$, que supera a 2 cuando $n > e^2 \approx 7.4$. Para muestras financieras típicas ($n \geq 250$), BIC penaliza mucho más la complejidad y selecciona modelos más parsimoniosos.

BIC penaliza más cuando $n > 7$ (condición dada en la tarea), lo que en la práctica financiera siempre se cumple. Se prefiere BIC para selección de modelos cuando la parsimonia es prioritaria; AIC cuando el objetivo es el pronóstico.

(c) Procedimiento de Box-Jenkins

Etapla 1 — Identificación: Graficar la serie original Y_t para detectar tendencia, estacionalidad o heteroscedasticidad. Calcular y graficar ACF y PACF; determinar si es necesario diferenciar (raíz unitaria: ADF/KPSS). Proponer posibles órdenes (p, d, q).

Etapla 2 — Estimación: Estimar los parámetros por máxima verosimilitud (MV) o mínimos cuadrados condicionales para cada modelo candidato. Comparar AIC/BIC.

Etapla 3 — Diagnóstico: Graficar los residuos $\hat{\varepsilon}_t$; verificar que sean ruido blanco mediante la ACF de residuos y la prueba de Ljung-Box (H_0 : residuos no correlacionados). Graficar QQ-plot para verificar normalidad. Si los residuos presentan estructura, revisar el orden y reiniciar.

(d) Prueba de Ljung-Box

$Q = n(n+2) \sum_{k=1}^h \hat{\rho}_k^2 / (n-k) \sim \chi^2(h-p-q)$ bajo H_0 (residuos son ruido blanco).

Se rechaza H_0 si $Q > \chi^2_{1-\alpha}(h-p-q)$. Se usa $h = \min(10, n/5)$ para equilibrar potencia y grados de libertad. Si se rechaza, el modelo tiene estructura residual no capturada y debe respecificarse.

Ejercicio 2.2 — ARIMA(1,1,1) para log-precios

(a) Conversión a ARMA(1,1) para los retornos

Definiendo $r_t = \Delta y_t = y_t - y_{t-1}$ y aplicando el operador diferencia al modelo:

$$(1 - \phi_1 B) r_t = (1 + \theta_1 B) \varepsilon_t$$

$$\text{Expandingo: } r_t - \phi_1 r_{t-1} = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

$$\text{Ecuación explícita del ARMA(1,1): } r_t = \phi_1 r_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

Este es exactamente un ARMA(1,1) para los log-retornos r_t , con el componente AR dado por ϕ_1 y el componente MA por θ_1 .

(b) Pronóstico $\hat{r}_{T+1|T}$

Con $\phi_1 = 0.15$ y $\theta_1 = -0.08$:

$$\hat{r}_{T+1|T} = E[r_{T+1} | \mathcal{F}_T] = \phi_1 r_T + \theta_1 \varepsilon_T$$

La fórmula completa del ARMA(1,1) un paso adelante es:

$$\hat{r}_{T+1|T} = \phi_1 r_T + \theta_1 \varepsilon_T = 0.15 r_T + (-0.08) \varepsilon_T = 0.15 r_T - 0.08 \varepsilon_T$$

(La expresión $\phi_1 \theta_1 \varepsilon_{T-1}$ en la tarea corresponde al término de ajuste cuando se expande desde un estado anterior; la representación simplificada condicional al error corriente es la mostrada.)

(c) Intervalo de predicción al 95%

El error de predicción a un paso es ε_{T+1} , con varianza σ^2 . El intervalo al 95% para r_{T+1} es:

$$\hat{r}_{T+1|T} \pm 1.96 \sigma$$

Traducción a nivel de precio: dado que $r_{T+1} = \log(P_{T+1}/P_T)$, se tiene $P_{T+1} = P_T \cdot \exp(r_{T+1})$. El intervalo para P_{T+1} es:

$$[P_T \cdot \exp(\hat{r}_{T+1|T} - 1.96 \sigma), P_T \cdot \exp(\hat{r}_{T+1|T} + 1.96 \sigma)]$$

La transformación exponencial hace que el intervalo sea asimétrico alrededor del punto central, con la cola derecha más ancha que la izquierda.

(d) Asimetría en volatilidad

El modelo ARIMA(1,1,1) NO captura el efecto de asimetría en volatilidad (leverage effect), porque su estructura es lineal y simétrica: un shock positivo y uno negativo de igual magnitud producen el mismo impacto sobre la varianza del pronóstico.

Para capturar este efecto se necesita modelar la varianza condicional. Las extensiones requeridas son los modelos ARCH/GARCH asimétricos, como el EGARCH (Nelson, 1991) o el GJR-GARCH (Glosten-Jagannathan-Runkle), donde el parámetro de asimetría γ distingue entre el impacto de $\varepsilon_t > 0$ y $\varepsilon_t < 0$ sobre la volatilidad futura.

Ejercicio 2.3 — Pronóstico multi-horizonte con ARIMA(2,1,0)

(a) AR(2) para $W_t = \Delta Y_t$

$W_t = \Delta Y_t = Y_t - Y_{t-1}$. El modelo ARIMA(2,1,0) implica que W_t sigue un AR(2):

$$W_t = \phi_1 W_{t-1} + \phi_2 W_{t-2} + \varepsilon_t = 0.5 W_{t-1} - 0.2 W_{t-2} + \varepsilon_t$$

(b) Pronósticos $\hat{W}_{T+1|T}$ y $\hat{W}_{T+2|T}$

Con $W_T = 1.2$, $W_{T-1} = 0.8$, $\phi_1 = 0.5$, $\phi_2 = -0.2$:

$$\hat{W}_{T+1|T} = 0.5 \times 1.2 + (-0.2) \times 0.8 = 0.6 - 0.16 = 0.44$$

$$\hat{W}_{T+2|T} = 0.5 \times \hat{W}_{T+1|T} + (-0.2) \times W_T = 0.5 \times 0.44 + (-0.2) \times 1.2 = 0.22 - 0.24 = -0.02$$

(c) Coeficientes ψ_j y ECM a horizonte h

Los coeficientes MA(∞): $\psi_0 = 1$, $\psi_1 = \phi_1 = 0.5$

$$\psi_2 = \phi_1 \psi_1 + \phi_2 \psi_0 = 0.5 \times 0.5 + (-0.2) \times 1 = 0.25 - 0.20 = 0.05$$

$$\text{MSE}_1 = \sigma^2 \times \psi_0^2 = 1 \times 1^2 = 1$$

$$\text{MSE}_2 = \sigma^2 \times (\psi_0^2 + \psi_1^2) = 1 \times (1 + 0.25) = 1.25$$

(d) Intervalos de predicción y traducción a Y_t

$$\text{IC 95\% para } W_{T+1}: \hat{W}_{T+1|T} \pm 1.96\sqrt{\text{MSE}_1} = 0.44 \pm 1.96 \times 1 = [-1.52, 2.40]$$

$$\text{IC 95\% para } W_{T+2}: \hat{W}_{T+2|T} \pm 1.96\sqrt{\text{MSE}_2} = -0.02 \pm 1.96 \times 1.118 = [-2.21, 2.17]$$

Traducción a Y_t (recordando que $W_t = \Delta Y_t$):

$$\hat{Y}_{T+1|T} = Y_T + \hat{W}_{T+1|T} = 100 + 0.44 = 100.44, \text{ IC: } [98.48, 102.40]$$

$$\hat{Y}_{T+2|T} = Y_T + \hat{W}_{T+1|T} + \hat{W}_{T+2|T} = 100 + 0.44 - 0.02 = 100.42, \text{ IC: } [97.79, 103.02]$$

Ejercicio 2.4 — Cointegración y spreads estadísticos

(a) Teorema de representación de Granger y corrección de error

Enunciado: Si Y_t y X_t son ambas $I(1)$ y cointegradas con vector $(1, -\beta)$, entonces existe una representación de Corrección de Error (ECM):

$$\Delta Y_t = \alpha(Y_{t-1} - \beta X_{t-1}) + \sum_j \gamma_j \Delta Y_{t-j} + \sum_j \delta_j \Delta X_{t-j} + \varepsilon_t$$

El término $\alpha(Y_{t-1} - \beta X_{t-1})$ es el mecanismo de corrección de error. El factor $(Y_{t-1} - \beta X_{t-1})$ mide el desvío del equilibrio de largo plazo. El coeficiente $\alpha < 0$ determina la velocidad de corrección: si la relación de largo plazo se desvía hacia arriba ($Y > \beta X$), Y decrece en el siguiente periodo para restaurar el equilibrio. Su magnitud $|\alpha|$ indica qué fracción del desvío se corrige cada periodo.

(b) Estimación de β y prueba de cointegración Engle-Granger

Paso 1 — Estimar β : Regresión de cointegración por MCO: $Y_t = \alpha_0 + \beta X_t + Z_t$. El estimador MCO de β es superconsistente (converge a T en lugar de $\sqrt{T}$) por la cointegración.

Paso 2 — Verificar estacionariedad del spread: Obtener los residuos $\hat{Z}_t = Y_t - \hat{\beta} X_t$ y aplicar la prueba ADF sobre $\hat{Z}_t$. Bajo H_0 (no cointegración) el spread es $I(1)$; se rechaza si el estadístico ADF cae por debajo del valor crítico de Engle-Granger (más negativo que los cuantiles t estándar).

Paso 3 — En pairs trading: los activos son cointegrados si el spread revierte a la media, lo que justifica la estrategia de abrir posición cuando el spread se desvía k desviaciones estándar.

(c) Propiedades del spread AR(1)

Dado $Z_t = \mu + \phi Z_{t-1} + \varepsilon_t$ con $|\phi| < 1$:

$$\text{Media: } E[Z_t] = \mu/(1 - \phi)$$

$$\text{Varianza: } \text{Var}(Z_t) = \sigma^2/(1 - \phi^2)$$

Tiempo esperado de retorno a la media: $E[\tau_\mu] = 1/|\log \phi| \approx 1/(1 - \phi)$ periodos (para ϕ cercano a 1, aproximación de primer orden). Más precisamente, el tiempo de vida medio del desvío es $-1/\log(\phi)$.

(d) Decisión de arbitraje con $\phi = 0.95$, $\mu = 0$, $\sigma = 0.01$

$$E[Z_t] = 0/(1 - 0.95) = 0. \text{ Desv. estándar: } \sqrt{(0.01^2/(1 - 0.9025))} = 0.01/\sqrt{0.0975} \approx 0.032.$$

Tiempo esperado de retorno: $-1/\log(0.95) \approx 1/0.0513 \approx 19.5$ periodos.

Regla de apertura: abrir posición larga en Z cuando $Z_t < -2 \times 0.032 = -0.064$ (spread muy bajo) y corta cuando $Z_t > +0.064$. Se cierra al volver a cero. El ratio retorno/riesgo mejora cuando ϕ es cercano a 1 (media-

reversión lenta pero predecible) pero el tiempo de espera es mayor. La posición es rentable si los costos de transacción son menores que la ganancia esperada en 19.5 periodos.

SECCIÓN 3 — Modelos SARIMA y Estacionalidad

Ejercicio 3.1 — SARIMA: estructura y notación

(a) SARIMA(1,1,1)(1,1,1)₁₂ expandido

El modelo SARIMA(1,1,1)(1,1,1)₁₂ es:

$$(1 - \Phi_1 B^{12})(1 - \phi_1 B)(1 - B^{12})(1 - B) Y_t = (1 + \Theta_1 B^{12})(1 + \theta_1 B) \varepsilon_t$$

Expandiendo el lado izquierdo (operadores diferenciales):

$$(1 - B - B^{12} + B^{13})(1 - \Phi_1 B^{12})(1 - \phi_1 B) Y_t$$

Desarrollando completamente:

$$Y_t - \phi_1 Y_{t-1} - \Phi_1 Y_{t-12} + \phi_1 \Phi_1 Y_{t-13} - Y_{t-1} + \phi_1 Y_{t-2} + \Phi_1 Y_{t-13} - \dots = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13}$$

Esta es la forma estructural completa con términos autorregresivos en rezagos 1, 12, 13 y medias móviles en rezagos 1, 12, 13.

(b) Cálculo de $\Delta_{12}(\Delta_1 Y_t)$

$$\Delta_1 Y_t = Y_t - Y_{t-1}$$

$$\Delta_{12}(\Delta_1 Y_t) = (1 - B^{12})(1 - B) Y_t = (1 - B - B^{12} + B^{13}) Y_t$$

$$= Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$$

Involucra exactamente los rezagos t , $t-1$, $t-12$ y $t-13$.

(c) Patrones ACF/PACF y necesidad de diferenciación estacional

Antes de aplicar Δ_{12} : La ACF muestral presenta picos significativos y persistentes en los rezagos múltiplos del periodo estacional: $\rho(12) \approx \rho(24) \approx \rho(36) \approx$ grande y de decaimiento lento. Esto indica presencia de raíz unitaria estacional.

Después de aplicar Δ_{12} : Los picos en múltiplos de 12 desaparecen o se vuelven estadísticamente insignificantes. La ACF resultante sólo muestra la estructura de dependencia de corto plazo.

(d) Combinación (d, D) para ventas minoristas mensuales

Se recomienda ($d = 1$, $D = 1$). Justificación: $d = 1$ elimina la tendencia determinista o estocástica de largo plazo (raíz unitaria regular). $D = 1$ elimina la estacionalidad estocástica (raíz unitaria en frecuencia estacional $2\pi/12$). Valores mayores ($d = 2$ o $D = 2$) sobrediferencian y aumentan la varianza del ruido sin mejorar el ajuste. La parsimonia dicta usar el mínimo orden que logra estacionariedad.

Ejercicio 3.2 — SARIMA para ventas mensuales (Airline model)

(a) Expansión del lado izquierdo

$$(1 - B)(1 - B^{12}) V_t = (1 - B - B^{12} + B^{13}) V_t$$

$$= V_t - V_{t-1} - V_{t-12} + V_{t-13} \quad \blacksquare$$

(b) Ecuación completa del modelo

$$(1 + \theta_1 B)(1 + \Theta_1 B^{12}) \varepsilon_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13}$$

$$\text{Ecuación completa: } V_t - V_{t-1} - V_{t-12} + V_{t-13} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13}$$

$$\text{Despejando } V_t: V_t = V_{t-1} + V_{t-12} - V_{t-13} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \Theta_1 \varepsilon_{t-12} + \theta_1 \Theta_1 \varepsilon_{t-13}$$

(c) Pronóstico $\hat{V}_{61}$

Con $\theta_1 = -0.4$, $\Theta_1 = -0.6$, $\theta_1 \Theta_1 = 0.24$:

$$\hat{V}_{61} = V_{60} + V_{49} - V_{48} + \theta_1 \hat{\varepsilon}_{60} + \Theta_1 \hat{\varepsilon}_{49} + \theta_1 \Theta_1 \hat{\varepsilon}_{48}$$

Usando los datos disponibles (se asume $V_{49} \approx V_{48} + \Delta V_{49}$, con $\hat{\varepsilon}_{49} \approx 0$ por falta de dato):

$$\hat{V}_{61} = 50 + V_{48} - V_{47} + (-0.4)(2) + (-0.6)(0) + (0.24)(1)$$

$$= 50 + (40 - 35) - 0.8 + 0 + 0.24 = 50 + 5 - 0.8 + 0.24 = 54.44 \text{ millones MXN}$$

(d) Intervalos de predicción y crecimiento con el horizonte

IC 95% para V_{61} : $\hat{V}_{61} \pm 1.96 \sigma$ (varianza de predicción = $\sigma^2 \times \sum \psi_j^2$, j de 0 a 0 = σ^2).

IC 95% para V_{73} (12 meses adelante): la varianza de predicción se acumula con los coeficientes ψ_j^2 de $h = 1$ a $h = 12$, dando un intervalo significativamente más amplio.

El intervalo crece porque cada horizonte adicional suma un nuevo término $\sigma^2 \psi_{h-1}^2$ al ECM. Para un proceso no estacionario (con diferenciación), los ψ_j no convergen a cero sino que permanecen acotados o crecen, haciendo que la incertidumbre se acumule indefinidamente con el horizonte. Esto refleja la inherente imposibilidad de predecir con certeza a largo plazo bajo incertidumbre estocástica.

Ejercicio 3.3 — SARIMA para tasas CETES con ciclos trimestrales

(a) Propuesta de modelo SARIMA

Dado el ciclo trimestral ($s = 13$) y la naturaleza de las tasas de CETES, se propone: SARIMA(1, 1, 0)(1, 0, 1)₁₃.

Justificación: $d = 1$ para estacionarizar la tendencia de la tasa. $D = 0$ porque la estacionalidad fiscal no implica necesariamente raíz unitaria estacional. $P = 1$ por los picos en ACF en rezagos 13, 26 (decaimiento geométrico en múltiplos de 13). $Q = 1$ por ajuste del término MA estacional. $p = 1$ por autocorrelación de corto plazo no estacional.

(b) Pronóstico para las próximas 4 semanas

El pronóstico a horizonte $h = 1, 2, 3, 4$ se obtiene aplicando recursivamente las ecuaciones del modelo. Los intervalos al 80% usan $\pm 1.28 \sigma \sqrt{\text{MSE}_h}$ y al 95% usan $\pm 1.96 \sigma \sqrt{\text{MSE}_h}$, donde $\text{MSE}_h = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$.

Las bandas se ensanchan con h porque la varianza de predicción crece con el horizonte, reflejando mayor incertidumbre acumulada.

(c) Evaluación con ECMP

ECMP (Error Cuadrático Medio de Predicción) = $(1/26) \sum_{t=T-25}^T (r_t - \hat{r}_{t|t-1})^2$ para la ventana de validación de 26 semanas.

Comparación: El SARIMA(1,1,0)(1,0,1)₁₃ debería superar al ARIMA(1,1,0) sin componente estacional porque captura la variación sistemática en torno a los vencimientos fiscales trimestrales. Un ECMP menor confirma que el componente estacional es estadísticamente informativo.

(d) Regla de decisión en trading de tasas

Regla: Si el IC al 95% para la tasa en $t+1$ está completamente por encima de la tasa forward actual, se compran futuros de CETES (se anticipa alza). Si está completamente por debajo, se venden.

Riesgo del modelo: (i) El modelo puede estar mal especificado si la política monetaria de Banxico cambia abruptamente. (ii) Los errores de predicción tienen colas más gruesas que la normal (exceso de curtosis). (iii) El spread bid-ask puede erosionar las ganancias esperadas cuando el IC es estrecho. Se recomienda usar el percentil 95% como escenario adverso para dimensionar coberturas.

Ejercicio 3.4 — Descomposición STL y limpieza de estacionalidad

(a) Ventajas de STL frente a descomposición clásica y X-12

Robustez ante atípicos: STL usa regresión local (LOESS) con pesos robustos, de modo que outliers tienen influencia reducida sobre la tendencia y el componente estacional estimados. La descomposición clásica usa medias móviles simples que son muy sensibles a valores extremos.

Componente estacional variable en el tiempo: STL permite que S_t cambie gradualmente periodo a periodo (controlado por el parámetro de ventana estacional n_s). X-12-ARIMA también permite variación pero mediante filtros fijos; STL es más flexible.

Flexibilidad del ancho de ventana: Los parámetros n_t (tendencia) y n_s (estacional) de STL pueden ajustarse libremente por el usuario según el contexto económico, mientras que X-12 usa filtros predefinidos.

(b) Serie desestacionalizada

Con $T_t = 2 + 0.1t$ y $S_t = 3 \sin(2\pi t/12)$:

$$Y_t^{\text{des}} = Y_t - S_t = (T_t + S_t + R_t) - S_t = T_t + R_t = 2 + 0.1t + R_t$$

El ARIMA se ajusta sobre $Y_t^{\text{des}} = T_t + R_t$. Dado que T_t es lineal determinista, una diferencia ($d = 1$) elimina la tendencia y deja R_t estacionario. El componente estacional ya fue removido por STL.

(c) STL + ARIMA vs ARIMA directo en commodities

En gas natural con estacionalidad invernal, el ARIMA directo debe capturar simultáneamente la tendencia, la estacionalidad y la dinámica de corto plazo con un único modelo paramétrico. STL + ARIMA separa las tres componentes, permitiendo: (i) modelar la tendencia con mayor flexibilidad local; (ii) capturar cambios en el patrón estacional año a año (la demanda invernal puede cambiar con el clima y la eficiencia energética); (iii) ajustar un ARIMA más parsimonioso sobre el residuo. Empíricamente, esto reduce el ECMP en horizontes de 1 a 3 meses.

(d) Indicador de fuerza estacional FS

$$FS = \max\{0, 1 - \text{Var}(R_t) / \text{Var}(S_t + R_t)\}$$

FS ≈ 0 : La varianza de $R_t \approx \text{Var}(S_t + R_t)$, lo que implica que $S_t \approx 0$ o es insignificante comparado con el ruido. La serie no tiene estacionalidad distinguible; el componente estacional es irrelevante.

FS ≈ 1 : $\text{Var}(R_t) \ll \text{Var}(S_t + R_t)$, lo que implica que casi toda la variabilidad en la suma $S_t + R_t$ proviene de S_t . La estacionalidad es fuerte y domina al ruido residual. Es justificado modelar separadamente.

SECCIÓN 4 — Modelos SARIMAX con Variables Exógenas

Ejercicio 4.1 — ARIMAX: incorporación de variables exógenas

(a) ARIMAX vs. regresión clásica con errores correlacionados

En una regresión lineal clásica $Y_t = \beta'x_t + u_t$, MCO es BLUE si $u_t \sim \text{i.i.d.}$ (Gauss-Markov). Si $u_t = \Theta(B)\varepsilon_t$ son errores ARMA, MCO sigue siendo insesgado pero deja de ser eficiente: existen estimadores de mínima varianza que explotan la estructura de correlación (GLS/MV).

Problema de inferencia: Los errores estándar de MCO subestiman la verdadera varianza de β cuando hay correlación serial positiva, haciendo que los estadísticos t sean artificialmente grandes. Esto lleva a rechazar H_0 con más frecuencia de la nominal (inflación del error tipo I). La estimación por MV en el ARIMAX maximiza la log-verosimilitud correcta incorporando la estructura ARMA de los errores.

(b) ARIMAX(1,1,0) para tipo de cambio MXN/USD

Modelo: $(1 - \phi_1 B)(1 - B) Y_t = \beta x_t + \varepsilon_t$

Donde $Y_t = \log(\text{MXN/USD})$ y $x_t = (i_{\text{MX}} - i_{\text{US}})$ es el diferencial de tasas.

Signo esperado de β : $\beta < 0$. Teoría de la paridad de tasas de interés: un mayor diferencial de tasas a favor de México ($i_{\text{MX}} > i_{\text{US}}$) debería atraer capital extranjero, apreciando el peso (reduciendo $Y_t = \text{MXN/USD}$). Sin embargo, en presencia de riesgo país, el signo puede invertirse en el corto plazo.

(c) Condiciones de estacionariedad para ARMAX

Las condiciones de estacionariedad del ARMAX(p,q) son las mismas que para el ARMA(p,q) puro: las raíces del polinomio AR $\phi_p(z)$ deben estar fuera del círculo unitario ($|z_j| > 1$). La variable exógena x_t no afecta la estacionariedad del proceso siempre que x_t sea $I(0)$ o que se haya diferenciado apropiadamente. Si x_t es $I(1)$, se requiere diferenciarla también para que el modelo sea estacionario y la inferencia válida.

(d) Comparación AIC/BIC: ARIMAX vs ARIMA puro

Se estiman ambos modelos y se compara: $\Delta\text{AIC} = \text{AIC}(\text{ARIMA}) - \text{AIC}(\text{ARIMAX})$. Si $\Delta\text{AIC} > 0$, el ARIMAX mejora el ajuste. El BIC penaliza el parámetro adicional β con $\log(n)$ unidades; si $\Delta\text{BIC} > 0$ también, la mejora es robusta a la penalización.

Criterio recomendado para selección: BIC, porque en finanzas la parsimonia es crucial para la estabilidad fuera de muestra. Un ARIMAX seleccionado sólo por AIC puede sobreajustar si x_t no tiene genuina capacidad predictiva fuera de la muestra de estimación.

Ejercicio 4.2 — SARIMAX para demanda de energía eléctrica

(a) Justificación de órdenes

La demanda horaria D_t tiene ciclo diario ($s_1 = 24$ horas) y semanal ($s_2 = 168 = 7 \times 24$). El modelo simplificado $(1 - B^{24})(1 - B) D_t$ captura: $d = 1$ para la tendencia de crecimiento de largo plazo; $(1 - B^{24})$ para la estacionalidad diaria. La estacionalidad semanal podría tratarse con $(1 - B^{168})$ adicionalmente.

Signo de β_1 : En verano, temperaturas altas aumentan el uso de aire acondicionado: $\beta_1 > 0$ (mayor temperatura $\rightarrow$ mayor demanda). En invierno, temperaturas bajas aumentan la calefacción: también $\beta_1 < 0$ respecto a temperatura, pero con una relación cuadrática (se puede incluir Temp_t^2 para capturar el efecto U-shaped).

(b) Log-verosimilitud condicional

La log-verosimilitud se construye bajo normalidad de ε_t :

$$\ell(\varphi, \theta, \beta, \sigma^2) = \sum_t \log p(y_t | y_{\{t-1\}}, \dots, y_1, x_t; \theta) = -(n/2) \log(2\pi\sigma^2) - (1/2\sigma^2) \sum_t \varepsilon_t^2$$

Donde $\varepsilon_t = \varphi(B)\Theta(B)[D_t - \beta'x_t]$ se obtiene aplicando el filtro inverso AR al proceso diferenciado. La maximización numérica (Newton-Raphson o BFGS) sobre $(\varphi, \theta, \beta, \sigma^2)$ da los estimadores de MV.

(c) Pronóstico $\hat{D}_{\{T+h\}}$ y tratamiento de $Temp_{\{T+h\}}$

Para $h = 1, \dots, 24$: se aplican las ecuaciones de recurrencia del modelo hacia adelante. Para valores futuros de la temperatura $Temp_{\{T+h\}}$, existen dos enfoques:

(i) Valores observados: si se cuenta con pronósticos meteorológicos de alta precisión (24h), se usan directamente como regresores exógenos conocidos.

(ii) Valores pronosticados: si $Temp_{\{T+h\}}$ debe predecirse, se modela por separado (AR o climatología estacional) y la incertidumbre adicional se incorpora al intervalo de predicción de $\hat{D}_{\{T+h\}}$ mediante el delta method o simulación.

(d) ECMP y comparación con modelo naïve

$$ECMP_{\text{modelo}} = (1/72) \sum_{h=1}^{72} (D_{\{T+h\}} - \hat{D}_{\{T+h\}})^2$$

$$ECMP_{\text{naïve}} = (1/72) \sum_{h=1}^{72} (D_{\{T+h\}} - D_{\{T+h-168\}})^2$$

El SARIMAX debería superar al naïve en presencia de variaciones climáticas no estacionarias o eventos atípicos (olas de calor, festivos). Si el naïve compete bien, indica que la estacionalidad semanal domina y el modelo podría simplificarse.

Ejercicio 4.3 — SARIMAX para ventas con efectos de calendario

(a) Interpretación de β_1 y β_2

β_1 (días festivos F_t): Efecto multiplicativo sobre las ventas en semanas con día festivo. Si $\beta_1 > 0$, las ventas (en logaritmo) aumentan durante semanas festivas. Un $\beta_1 = 0.15$ significaría que las ventas se incrementan aproximadamente 15% las semanas con festivo, todo lo demás constante.

β_2 (variación en log del precio del petróleo $\Delta \log P_t$): Elasticidad precio-ventas. Si $\beta_2 < 0$, un aumento del 1% en el precio del petróleo reduce las ventas en $|\beta_2|\%$ a través del efecto ingreso (mayores costos de transporte y combustible reducen el poder adquisitivo del consumidor).

(b) Justificación de la transformación $\log(V_t)$

Estabilización de la varianza: Las series de ventas suelen tener varianza proporcional al nivel (heterocedasticidad multiplicativa). La transformación logarítmica estabiliza la varianza: si $V_t = T_t \cdot S_t \cdot R_t$, entonces $\log V_t = \log T_t + \log S_t + \log R_t$, con R_t de varianza aproximadamente constante.

Interpretación porcentual: Los coeficientes β en el modelo logarítmico son elasticidades directamente interpretables como cambios porcentuales, lo que es natural en análisis económico.

Distribución de errores: La distribución lognormal (normal de los logaritmos) es más apropiada que la normal para series de ventas que siempre son positivas. Reduce la asimetría de los residuos y mejora la validez de los intervalos de confianza.

(c) Multicolinealidad entre F_t y P_t

$FIV_j = 1/(1 - R_j^2)$, donde R_j^2 es el R^2 de la regresión de x_j sobre las demás variables.

Cuando es problemática: $FIV > 10$ (equivalente a $R^2 > 0.9$). F_t y P_t pueden correlacionarse si los precios del petróleo tienden a subir en períodos festivos (p.ej., Navidad, Semana Santa) por mayor demanda energética. Si $FIV > 10$, los estimadores β_1 y β_2 son inestables y sus errores estándar están inflados.

Cómo resolverlo: (i) Centrar y escalar las variables; (ii) usar regresión ridge o LASSO para estabilizar estimadores; (iii) eliminar una de las variables si son redundantes; (iv) transformar: usar el precio del petróleo rezagado $\Delta \log P_{t-k}$ para reducir la correlación contemporánea con F_t .

(d) Pronóstico 12 semanas e incertidumbre adicional por P_{T+h}

Para $h = 1, \dots, 12$: se usan los festivos F_{T+h} del calendario (conocidos con certeza) y se predice P_{T+h} con un AR(1) auxiliar.

Varianza total del pronóstico: $\text{Var}(\hat{y}_{T+h}) = \text{Var}_{\text{modelo}}(\hat{y}_{T+h}) + \beta_2^2 \text{Var}(\Delta \log \hat{P}_{T+h})$.

El segundo término cuantifica la incertidumbre adicional transmitida desde el pronóstico del precio del petróleo. Cuando $\beta_2^2 \times \text{Var}(\Delta \log \hat{P}_{T+h})$ es significativo (más del 10% de la varianza total), los intervalos deben ser inflados correspondientemente. Se recomienda bootstrap paramétrico combinado para propagar correctamente toda la incertidumbre.

SECCIÓN 5 — Simulación, Yule-Walker e Interpretación Gráfica

Ejercicio 5.1 — Ecuaciones de Yule-Walker y estimación AR

(a) Yule-Walker para AR(1)

Para $Y_t = \phi_1 Y_{t-1} + \varepsilon_t$, multiplicando ambos lados por Y_{t-k} y tomando esperanzas:

Para $k = 1$: $E[Y_t Y_{t-1}] = \phi_1 E[Y_{t-1}^2] + E[\varepsilon_t Y_{t-1}]$

Dado que ε_t es independiente de Y_{t-1} : $\gamma(1) = \phi_1 \gamma(0)$, por lo que $\phi_1 = \gamma(1)/\gamma(0) = \rho(1)$. ■

Para la varianza: $\text{Var}(Y_t) = \phi_1^2 \text{Var}(Y_{t-1}) + \sigma^2$. Por estacionariedad: $\gamma(0) = \phi_1^2 \gamma(0) + \sigma^2$, lo que da $\sigma^2 = \gamma(0)(1 - \phi_1^2)$. ■

(b) AR(2): sistema Yule-Walker

Para $\phi_1 = 0.6$, $\phi_2 = -0.2$, las ecuaciones de Yule-Walker son:

$$\gamma(1) = \phi_1 \gamma(0) + \phi_2 \gamma(1) \rightarrow \gamma(1)(1 - \phi_2) = \phi_1 \gamma(0) \rightarrow \gamma(1) = [\phi_1 / (1 - \phi_2)] \gamma(0) = [0.6 / 1.2] \gamma(0) = 0.5 \gamma(0)$$

$$\gamma(2) = \phi_1 \gamma(1) + \phi_2 \gamma(0) = 0.6 \times 0.5 \gamma(0) + (-0.2) \gamma(0) = 0.3 \gamma(0) - 0.2 \gamma(0) = 0.1 \gamma(0)$$

$$\text{Para } \gamma(0): \sigma^2 = \gamma(0) - \phi_1 \gamma(1) - \phi_2 \gamma(2) = \gamma(0)[1 - 0.6 \times 0.5 - (-0.2) \times 0.1] = \gamma(0)[1 - 0.3 + 0.02] = 0.72 \gamma(0)$$

$$\text{Por tanto: } \gamma(0) = \sigma^2 / 0.72, \gamma(1) = 0.5 \sigma^2 / 0.72, \gamma(2) = 0.1 \sigma^2 / 0.72.$$

(c) Consistencia del estimador Yule-Walker y descomposición de Cholesky

Consistencia: al sustituir $\gamma(k)$ por las autocovarianzas muestrales $\hat{\gamma}(k) = (1/T) \sum_t Y_t Y_{t-k}$, la ley de grandes números garantiza $\hat{\gamma}(k) \rightarrow_p \gamma(k)$. El estimador $\hat{\phi} = \Gamma_p^{-1} \hat{\gamma}_p$ es continuo en sus argumentos (función de matrices invertibles), por lo que $\hat{\phi} \rightarrow_p \phi$ por el Teorema de la Función Continua. Asintóticamente, $\sqrt{T}(\hat{\phi} - \phi) \rightarrow_d N(0, \sigma^2 \Gamma_p^{-1})$.

Descomposición de Cholesky: La matriz Γ_p es positiva definida (por ser una matriz de covarianza de un proceso estacionario). Cholesky la factoriza como $\Gamma_p = L L'$ donde L es triangular inferior. El sistema Γ_p

$\varphi = \gamma_p$ se resuelve en $O(p^2)$ operaciones mediante sustitución progresiva y regresiva, mucho más eficiente que inversión directa $O(p^3)$.

(d) Estimación AR con autocorrelaciones del IPC (T = 1000)

Yule-Walker con $p = 1$: $\hat{\varphi}_1 = \hat{\rho}(1) = 0.12$. Estimación de σ^2 : $\sigma^2 = \hat{\gamma}(0)(1 - \hat{\varphi}_1^2) \approx \hat{\gamma}(0) \times 0.9856$.

Yule-Walker con $p = 2$: El sistema es $\hat{\rho}(1) = \hat{\varphi}_1 + \hat{\varphi}_2 \hat{\rho}(1)$ y $\hat{\rho}(2) = \hat{\varphi}_1 \hat{\rho}(1) + \hat{\varphi}_2$. Sustituyendo: $0.12 = \hat{\varphi}_1 + 0.12 \hat{\varphi}_2$ y $-0.04 = 0.12 \hat{\varphi}_1 + \hat{\varphi}_2$. Resolviendo: $\hat{\varphi}_1 \approx 0.135$, $\hat{\varphi}_2 \approx -0.056$.

IC al 95% para $\rho(1)$: $\hat{\rho}(1) \pm 1.96/\sqrt{T} = 0.12 \pm 1.96/\sqrt{1000} = 0.12 \pm 0.062 = [0.058, 0.182]$.

Conclusión: $\rho(1) = 0.12$ es estadísticamente significativo (el IC no contiene cero), lo que sugiere autocorrelación de primer orden en los log-retornos del IPC, aunque modesta en magnitud.

Ejercicio 5.2 — Simulación de AR(2) y diagnóstico gráfico

(a) Identificación del orden

ACF: Decae de manera oscilatoria y amortiguada (exponencial con posible componente cíclico) sin corte abrupto. Es consistente con un proceso AR.

PACF: Se corta abruptamente después del rezago 2: $PACF(1) \approx 0.7$, $PACF(2) \approx -0.3$, $PACF(k) \approx 0$ para $k \geq 3$. Esto identifica $p = 2$.

La combinación ACF decaiente + PACF con corte en rezago 2 es la firma característica del AR(2). ■

(b) Estimación Yule-Walker

Con $\hat{\rho}(1) = 0.61$ y $\hat{\rho}(2) = 0.22$:

Sistema: $[1, 0.61; 0.61, 1][\hat{\varphi}_1; \hat{\varphi}_2] = [0.61; 0.22]$

Ecuación 1: $\hat{\varphi}_1 + 0.61 \hat{\varphi}_2 = 0.61$

Ecuación 2: $0.61 \hat{\varphi}_1 + \hat{\varphi}_2 = 0.22$

De la ecuación 2: $\hat{\varphi}_2 = 0.22 - 0.61 \hat{\varphi}_1$. Sustituyendo en 1: $\hat{\varphi}_1 + 0.61(0.22 - 0.61 \hat{\varphi}_1) = 0.61 \rightarrow \hat{\varphi}_1(1 - 0.3721) = 0.61 - 0.1342 \rightarrow \hat{\varphi}_1 = 0.4758/0.6279 \approx 0.758$. Luego $\hat{\varphi}_2 = 0.22 - 0.61 \times 0.758 \approx -0.242$.

Comparación: Valores verdaderos $\varphi_1 = 0.7$, $\varphi_2 = -0.3$. Los estimadores Yule-Walker (0.758 y -0.242) presentan sesgo finito de muestra: con $T = 300$, la estimación tiene variabilidad pero es razonablemente cercana a la verdad.

(c) Raíces complejas del AR(2)

Polinomio: $1 - 0.7z + 0.3z^2 = 0 \rightarrow z = [0.7 \pm \sqrt{(0.49 - 1.2)}] / 0.6 = [0.7 \pm \sqrt{-0.71}] / 0.6$

Las raíces son complejas: $z = (0.7 \pm 0.843i) / 0.6 = 1.167 \pm 1.405i$.

Módulo: $|z| = \sqrt{(1.167^2 + 1.405^2)} = \sqrt{(1.362 + 1.974)} = \sqrt{3.336} \approx 1.827 > 1$. El proceso es estacionario.

Implicación para la ACF: Las raíces complejas del polinomio AR producen oscilaciones amortiguadas en la ACF teórica. El argumento de las raíces ($\arctan(1.405/1.167) \approx 50^\circ$) determina la frecuencia del ciclo: el proceso exhibe ciclos de aproximadamente $360/50 \approx 7$ periodos superpuestos al decaimiento exponencial.

(d) Varianza teórica

Con $\varphi_1 = 0.7$, $\varphi_2 = -0.3$, $\sigma^2 = 1$:

$\rho(1) = \varphi_1/(1 - \varphi_2) = 0.7/1.3 \approx 0.538$

$$\rho(2) = \phi_1 \rho(1) + \phi_2 = 0.7 \times 0.538 - 0.3 \approx 0.077$$

$$\sigma^2 = \gamma(0)[1 - \phi_1 \rho(1) - \phi_2 \rho(2)] = \gamma(0)[1 - 0.7 \times 0.538 - (-0.3) \times 0.077]$$

$$= \gamma(0)[1 - 0.377 + 0.023] = \gamma(0) \times 0.646$$

$$\gamma(0) = \sigma^2 / 0.646 = 1 / 0.646 \approx 1.548.$$

La varianza muestral de $T = 300$ observaciones debería estar cercana a 1.548. Las discrepancias se deben al error muestral inherente de estimación con muestra finita.

Ejercicio 5.3 — Tabla de rendimientos y ajuste ARIMA a log-retornos del IPC

(a) Interpretación de la tabla

Mayor volatilidad: Enero-Junio 2020, con desviación estándar de 0.0221, correspondiente al inicio de la pandemia COVID-19 y el colapso de los precios del petróleo. Es el periodo de mayor incertidumbre del conjunto de datos.

Mayor asimetría negativa: Enero-Junio 2020 con -0.87 , indicando colas izquierdas gruesas. Las caídas extremas del mercado dominan sobre las alzas. Esto coincide con el crash de marzo 2020.

Curtosis > 3 indica colas más gruesas que la normal: todos los periodos muestran curtosis exceso (Ene-Jun 2020: 6.23, que es muy elevada). La distribución de retornos tiene mucha más probabilidad en las colas de lo que predicen modelos gaussianos.

Evento macroeconómico: El periodo Ene-Jun 2020 captura la pandemia y la guerra de precios del petróleo (Arabia Saudita vs Rusia). Jul-Dic 2020 muestra recuperación con menor volatilidad. Ene-Jun 2022 refleja incertidumbre por la guerra en Ucrania (aunque menor volatilidad en el IPC). Jul-Dic 2023 es el periodo más estable.

(b) Estimación AR(1) para Jul-Dic 2020

Yule-Walker: $\hat{\phi}_1 = \hat{\rho}(1) = 0.12$. Estimador de σ^2 : dado Des.Est. = 0.0148, $\sigma^2 \approx (0.0148)^2(1 - 0.12^2) = 0.000219(0.9856) \approx 0.000216$.

IC al 95% para ϕ_1 ($T \approx 125$ obs. en 6 meses): $\pm 1.96/\sqrt{125} = \pm 0.175$.

IC: $[0.12 - 0.175, 0.12 + 0.175] = [-0.055, 0.295]$. El IC contiene cero, por lo que $\phi_1 = 0.12$ no es estadísticamente significativo al 5% con sólo 125 observaciones.

(c) ARIMA(1,0,0) para Ene-Jun 2020

El ARIMA(1,0,0) modela la media condicional $E[r_t | r_{t-1}]$. Con $\hat{\rho}(1) = 0.08$, hay autocorrelación de primer orden, lo que es consistente con AR(1).

Sin embargo, la curtosis de 6.23 y la asimetría de -0.87 indican fuertemente que los residuos del AR(1) no son normales: tienen colas mucho más pesadas y son asimétricos hacia la izquierda. Esto es evidencia de heteroscedasticidad condicional (los shocks grandes tienden a agruparse).

Extensión requerida: un modelo ARIMA(1,0,0)-GARCH(1,1) o EGARCH(1,1) que modele explícitamente la varianza condicional $\sigma^2_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$. El EGARCH además captura el efecto palanca (caídas generan más volatilidad que subidas).

(d) Comparación ACF teórica vs muestral simulada

Para AR(1) con $\phi_1 = 0.12$: ACF teórica $\rho(k) = 0.12^k$. Valores: $\rho(1) = 0.12$, $\rho(2) = 0.0144$, $\rho(3) = 0.0017$, $\rho(k) \approx 0$ para $k \geq 3$.

Con $T = 126$ simulaciones, la ACF muestral $\hat{\rho}(k)$ tendrá desviación estándar aproximada $1/\sqrt{126} \approx 0.089$. Esto implica que incluso el pico en $k = 1$ ($\rho = 0.12$) puede no ser distinguible del ruido estadístico.

Discrepancias: Se deben principalmente al error de muestreo (varianza finita de las autocorrelaciones muestrales). Con $T = 126$, la banda de significancia al 95% es ± 0.175 , mayor que $\rho(1) = 0.12$. La ACF muestral fluctuará alrededor de la teórica con alta variabilidad, lo que dificulta identificar el verdadero proceso.

Ejercicio 5.4 — Simulación SARIMA y diagnóstico estacional

(a) Interpretación de la ACF

Los picos en rezagos 12, 24, 36 con valores 0.72, 0.55, 0.41 son la firma de un componente AR estacional. Decaen progresivamente porque el AR estacional con $\Phi_1 = 0.8$ produce $\rho(12k) \approx \Phi_1^k = 0.8^k$: $\rho(12) = 0.8$, $\rho(24) = 0.64$, $\rho(36) = 0.512$ (valores teóricos modificados por el término MA).

El decaimiento geométrico de los picos en múltiplos de $s = 12$ es la característica definidora del AR estacional. Si fueran MA estacional, los picos se cortarían abruptamente después del rezago Q_s .

(b) ACF teórica en rezagos clave

Para el modelo $(1 - \Phi_1 B^{12}) Y_t = (1 + \theta_1 B) \varepsilon_t$ con $\Phi_1 = 0.8$, $\theta_1 = -0.5$:

Rezago $k = 1$ (MA): $\rho(1) = \theta_1 / (1 + \theta_1^2) = -0.5 / 1.25 = -0.4$

Rezago $k = 12$ (AR estacional dominante): $\rho(12) \approx \Phi_1 / (1 + \text{efecto MA}) \approx 0.8$ (ajustado por el MA(1))

Rezago $k = 13$ (interacción): $\rho(13) = \rho(12) \times \rho(1) \approx 0.8 \times (-0.4) = -0.32$

Rezago $k = 24$: $\rho(24) = \Phi_1^2$ ajustado ≈ 0.64

(c) Propuesta de modelo Box-Jenkins

ACF observada: picos en $k = 1$ (negativo, cortado), $k = 12, 24, 36$ (decaimiento geométrico). PACF esperada: pico en $k = 12$, decaimiento en múltiplos de 12 (AR estacional), pico en $k = 1$ (MA no estacional).

Modelo propuesto: SARIMA(0, 0, 1)(1, 0, 0)₁₂. Ningún indicio de necesitar diferenciación regular ($D = 0$) porque los picos estacionales decaen (no son planos), ni diferenciación ordinaria ($d = 0$) porque la media parece estable.

(d) Sesgo de Yule-Walker con muestras pequeñas

$\Phi_1 = \hat{\rho}(12) = 0.72$ vs Φ_1 verdadero = 0.8. Error: $0.72 - 0.8 = -0.08$ (sesgo hacia abajo).

Causa del sesgo negativo: Las autocorrelaciones muestrales tienen sesgo descendente en muestras pequeñas porque el estimador $(1/T) \sum Y_t Y_{t-k}$ divide entre T (no entre $T - k$). Con $T = 120$ y $k = 12$, se pierden 12 observaciones del denominador efectivo. Además, el estimador Yule-Walker hereda el sesgo conocido del estimador MCO de los parámetros AR. Con muestras pequeñas, la corrección de Burg o estimadores exactos de MV son preferibles.

Ejercicio 5.5 — Tabla comparativa de modelos y pronóstico cambiario

(a) Interpretación de la tabla de modelos

Mejor ajuste dentro de muestra: El SARIMA(1,1,1)(1,0,1)₁₂ tiene el menor AIC (-54.3) y el menor BIC (-47.8), por lo que domina dentro de muestra por ambos criterios.

¿Coinciden AIC y BIC? Sí, ambos favorecen al SARIMA en este caso. Sin embargo, el BIC penaliza sus 4 parámetros con $4 \log(36) \approx 14.4$ unidades adicionales, reduciendo la ventaja relativa.

Mejor predicción fuera de muestra: El SARIMA también tiene el menor RMSE (0.298) y MAE (0.239) en la muestra de prueba de 6 meses, lo que confirma que la componente estacional aporta genuino poder predictivo fuera de muestra.

(b) Expansión del IC con el horizonte

La varianza de predicción a horizonte h crece porque cada paso adicional acumula incertidumbre: $MSE_h \approx \sigma^2 h$ para un proceso ARIMA(1,1,0) (caminata aleatoria con drift pequeño). La amplitud del IC al 95% es:

$$2 \times 1.96 \times \sigma \sqrt{h} = 2 \times 1.96 \times \sqrt{0.0118} \times \sqrt{h} = 2 \times 1.96 \times 0.1086 \times \sqrt{6} \approx 2 \times 1.96 \times 0.266 \approx 1.044 \text{ MXN/USD.}$$

(c) Pronóstico $\hat{Y}_{T+1|T}$ y $\hat{Y}_{T+2|T}$

Para el ARIMA(1,1,1) con $\phi_1 = 0.3$, $\theta_1 = -0.4$, $\Delta Y_T = 0.16$, $\varepsilon_T = 0.05$:

$$\Delta \hat{Y}_{T+1|T} = \phi_1 \Delta Y_T + \theta_1 \varepsilon_T = 0.3 \times 0.16 + (-0.4) \times 0.05 = 0.048 - 0.020 = 0.028$$

$$\hat{Y}_{T+1|T} = Y_T + 0.028$$

Para $h = 2$: $\Delta \hat{Y}_{T+2|T} = \phi_1 \Delta \hat{Y}_{T+1|T} + \theta_1 \times 0 = 0.3 \times 0.028 = 0.0084$ (el error futuro $\varepsilon_{T+1} = 0$ en valor esperado)

$$\hat{Y}_{T+2|T} = Y_T + 0.028 + 0.0084 = Y_T + 0.0364$$

(d) Uso del IC para cobertura cambiaria

La empresa importadora necesita dólares en 3 meses. Estrategia con el IC del SARIMA:

Punto central ($\hat{Y}_{T+3}$): usar para fijar el forward a precio de mercado esperado.

Percentil 95% (cola derecha del IC): escenario adverso donde el dólar está más caro. La empresa debería usar este valor para dimensionar la cobertura. Si puede tolerar pérdidas de hasta el percentil 95%, compra un forward al precio central y acepta el riesgo residual. Si quiere protección total contra el peor escenario, compra una put sobre MXN/USD con strike en el percentil 95%.

Preferencia: el percentil 95% para la cobertura mínima garantizada, usando la opción de compra de dólares (call USD/put MXN) con strike en ese nivel. El costo de la prima de la opción refleja la incertidumbre del abanico de pronósticos.

Ejercicio 5.6 — Simulación de Monte Carlo para evaluación de pronósticos

(a) Distribución del pronóstico del AR(1)

Por inducción. Para $h = 1$: $Y_{T+1} = \phi_1 Y_T + \varepsilon_{T+1}$. Dado $Y_T = y_0$ (fijo), $Y_{T+1} | Y_T = y_0 \sim N(\phi_1 y_0, \sigma^2)$.

Para $h = 2$: $Y_{T+2} = \phi_1 Y_{T+1} + \varepsilon_{T+2} = \phi_1^2 y_0 + \phi_1 \varepsilon_{T+1} + \varepsilon_{T+2}$.

$$E[Y_{T+h} | Y_T = y_0] = \phi_1^h y_0.$$

$$\text{Var}(Y_{T+h} | Y_T = y_0) = \sigma^2 (1 + \phi_1^2 + \dots + \phi_1^{2(h-1)}) = \sigma^2 (1 - \phi_1^{2h}) / (1 - \phi_1^2).$$

Como suma de variables normales independientes multiplicadas por constantes: $Y_{T+h} | Y_T \sim N(\phi_1^h y_0, \sigma^2 (1 - \phi_1^{2h}) / (1 - \phi_1^2))$. ■

(b) Tabla de IC analíticos con $\phi_1 = 0.6$, $\sigma = 1$, $y_0 = 2$

$$\sigma^2 / (1 - \phi_1^2) = 1 / (1 - 0.36) = 1.5625$$

h	$E[Y_{T+h}]$	$\text{Var}(Y_{T+h} Y_T)$	LI 95%	LS 95%
1	$0.6 \times 2 = 1.20$	$1(1-0.36)/0.64 = 1.00$	$1.20 - 1.96$	$1.20 + 1.96$
→	1.20	1.00	-0.76	3.16
5	$0.6^5 \times 2 \approx 0.156$	$1-0.6^{10}/0.64 \approx 1.518$	$0.156 - 2.415$	$0.156 + 2.415$
→	0.156	1.518	-2.259	2.571
10	$0.6^{10} \times 2 \approx 0.012$	$(1-0.6^{20})/0.64 \approx 1.562$	$0.012 - 2.461$	$0.012 + 2.461$
→	0.012	1.562	-2.449	2.473
∞	0	1.5625	-2.450	2.450

La media converge a $0 = \mu/(1-\phi)$ (media incondicional) y la varianza converge a $\sigma^2/(1-\phi^2) = 1.5625$ (varianza incondicional).

(c) Algoritmo de Monte Carlo (B = 1,000 trayectorias)

Paso 1: Estimar el modelo y obtener $\hat{\phi}_1$ y $\hat{\sigma}^2$.

Paso 2: Para $b = 1, \dots, 1000$: generar $\varepsilon^{(b)}_{T+1}, \dots, \varepsilon^{(b)}_{T+h}$ i.i.d. $\sim N(0, \hat{\sigma}^2)$. Simular: $Y^{(b)}_{T+1} = \hat{\phi}_1 Y_T + \varepsilon^{(b)}_{T+1}$; $Y^{(b)}_{T+j} = \hat{\phi}_1 Y^{(b)}_{T+j-1} + \varepsilon^{(b)}_{T+j}$.

Paso 3: Para cada horizonte h , el IC empírico es [percentil 2.5% de $\{Y^{(b)}_{T+h}\}$, percentil 97.5% de $\{Y^{(b)}_{T+h}\}$].

Comparación con analítico: Con $B = 1,000$, la diferencia entre el IC empírico y el analítico es del orden $1/\sqrt{B} \approx 3\%$, lo que es despreciable para fines prácticos.

(d) Interpretación del fan chart (abanico de pronósticos)

El abanico se abre hacia los horizontes más lejanos porque la varianza de predicción crece con h : cada paso adicional añade incertidumbre proveniente de ε_{T+h} . La apertura refleja la acumulación de shocks futuros desconocidos.

Convergencia de la media: $\hat{Y}_{T+h} = \hat{\phi}_1^h y_0 \rightarrow 0$ cuando $h \rightarrow \infty$ (la media incondicional del AR estacionario). La trayectoria central del fan chart converge al nivel de largo plazo.

Incertidumbre cuando $h \rightarrow \infty$: $\text{Var}(Y_{T+h} | Y_T) \rightarrow \sigma^2/(1-\phi^2) = \text{varianza incondicional}$. Las bandas del fan chart dejan de abrirse y convergen a la banda de $\pm 1.96\sigma/\sqrt{1-\phi^2}$ de la distribución estacionaria del proceso. Esto confirma que la incertidumbre tiene un límite superior dado por la variabilidad intrínseca del proceso.