UNIVERSIDAD PANAMERICANA

Facultad de Ciencias Empresariales

Tarea: Series de Tiempo para Finanzas

ARIMA(p,d,q) · SARIMA · Pronóstico

Dr. César Galindo | Verano 2026

Solución completa — Ejercicios 1.1 al 3.3

SECCIÓN 1 — Procesos Estacionarios y Fundamentos

Ejercicio 1.1 — Estacionariedad, ACF y PACF

(a) Definiciones de estacionariedad

Un proceso estocástico $\{Y_t\}$ puede ser estacionario en dos sentidos distintos:

Estacionariedad débil (o de covarianza): El proceso $\{Y_t\}$ es débilmente estacionario si se satisfacen dos condiciones:

- $E[Y_t] = \mu$ para todo t (la media es constante en el tiempo).
- $Cov(Y_t, Y_{t-k}) = \gamma(k)$ depende únicamente del rezago k, no del momento t.

Estacionariedad estricta: El proceso es estrictamente estacionario si la distribución conjunta de cualquier colección finita $(Y_{t1}, \ldots, Y_{tm})$ es idéntica a la de $(Y_{t1+h}, \ldots, Y_{tm+h})$ para todo desplazamiento h. Es una condición mucho más fuerte: toda la distribución (no sólo los dos primeros momentos) es invariante al tiempo.

> 💡 *Relación: estacionariedad estricta + varianza finita implica estacionariedad débil. El recíproco es falso en general.*

Ejemplo: proceso débilmente pero NO estrictamente estacionario.

Sea $Y_t = \varepsilon_t \cdot \sigma_t$ donde $\varepsilon_t \sim N(0,1)$ i.i.d. y σ_t toma dos valores: σ_1 para t par y σ_2 para t impar (con $\sigma_1 \neq \sigma_2$). Si construimos $X_t = Y_t / \sigma_t$ (apropiado), se puede definir también: sea $Z_t = \mu + \varepsilon_t$ con $\varepsilon_t \sim$ Laplace(0,1) para t par y $\varepsilon_t \sim N(0,1)$ para t impar, pero ambas con media 0 y varianza 1. Entonces:

- $E[Z_t] = 0$ para todo t → media constante.
- $Cov(Z_t, Z_{t-k}) = 0$ para $k \geq 1$, $Var(Z_t) = 1$ → covarianza sólo depende de k.
- Pero la distribución marginal de Z_t cambia entre t par (Laplace) e impar (Normal), por lo que la distribución conjunta cambia con el tiempo → NO es estrictamente estacionario.

(b) Demostración: $|\rho(k)| \leq 1$ y $\rho(k) = \rho(-k)$

La función de autocorrelación se define como:

$$\rho(k) = \gamma(k) / \gamma(0) \quad \text{donde } \gamma(k) = Cov(Y_t, Y_{t-k}) \text{ y } \gamma(0) = Var(Y_t)$$

Simetría: $\rho(k) = \rho(-k)$

Por definición de covarianza:

$$\gamma(k) = Cov(Y_t, Y_{t-k}) = E[(Y_t-\mu)(Y_{t-k}-\mu)]$$

Hacemos el cambio de índice $s = t-k$, entonces $t = s+k$:

$$\gamma(k) = E[(Y_\{s+k\}-\mu)(Y_s-\mu)] = Cov(Y_s, Y_\{s+k\}) = \gamma(-k)$$

Por tanto: $\rho(k) = \gamma(k)/\gamma(0) = \gamma(-k)/\gamma(0) = \rho(-k)$. ■

Cota $|\rho(k)| \leq 1$ — Desigualdad de Cauchy-Schwarz

Para cualesquiera variables aleatorias X, Y con varianza finita:

$$[Cov(X,Y)]^2 \leq Var(X) \cdot Var(Y)$$

Aplicando con $X = Y_t$ y $Y = Y_{t-k}$ (que por estacionariedad tienen la misma varianza $\gamma(0)$):

$$[\gamma(k)]^2 \leq \gamma(0)\cdot\gamma(0) = [\gamma(0)]^2$$

Dividiendo entre $[\gamma(0)]^2$:

$$[\gamma(k)/\gamma(0)]^2 \leq 1 \quad \rightarrow \quad [\rho(k)]^2 \leq 1 \quad \rightarrow \quad |\rho(k)| \leq 1. \quad \blacksquare$$

💡 *$\rho(k) = 1$ sólo si Y_t y Y_{t-k} son perfectamente correlacionados; $\rho(k) = -1$ si son perfectamente anticorrelacionados.*

(c) AR(1): $Var(Y_t)$, $Cov(Y_t, Y_{t-1})$ y $\rho(k) = 0.6^k$

Modelo: $Y_t = 0.6\, Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \sim WN(0, \sigma^2)$ y $|0.6| < 1$ (estacionario).

Paso 1 — Calcular $Var(Y_t) = \gamma(0)$

Tomamos varianza en ambos lados:

$$Var(Y_t) = (0.6)^2 \cdot Var(Y_{t-1}) + Var(\varepsilon_t) \quad [\text{independencia de } \varepsilon_t \text{ con el pasado}]$$

Por estacionariedad $Var(Y_t) = Var(Y_{t-1}) = \gamma(0)$:

$$\gamma(0) = 0.36\cdot\gamma(0) + \sigma^2 \quad \rightarrow \quad \gamma(0)(1 - 0.36) = \sigma^2$$

$$\gamma(0) = \sigma^2 / (1 - 0.36) = \sigma^2 / 0.64$$

✓ **$Var(Y_t) = \sigma^2 / (1 - 0.6^2) = \sigma^2 / 0.64$**

Paso 2 — Calcular $Cov(Y_t, Y_{t-1}) = \gamma(1)$

Multiplicamos la ecuación del modelo por $(Y_{t-1} - \mu)$ y tomamos esperanza ($\mu=0$ para simplificar):

$$E[Y_t \cdot Y_{t-1}] = 0.6\cdot E[Y_{t-1}^2] + E[\varepsilon_t \cdot Y_{t-1}]$$

Como ε_t es ruido blanco, $E[\varepsilon_t \cdot Y_{t-1}] = 0$ (ε_t independiente del pasado):

$$\gamma(1) = 0.6\cdot\gamma(0) = 0.6\cdot\sigma^2/0.64 = 0.6\sigma^2/0.64$$

✓ **$Cov(Y_t, Y_{t-1}) = 0.6\cdot\gamma(0) = 0.6\sigma^2/0.64$**

Paso 3 — Demostrar $\rho(k) = 0.6^k$ para $k \geq 0$

Multiplicamos $Y_t = 0.6Y_{t-1} + \varepsilon_t$ por Y_{t-k} y tomamos $E[\cdot]$:

$$\gamma(k) = 0.6\cdot\gamma(k-1) + E[\varepsilon_t \cdot Y_{t-k}] = 0.6\cdot\gamma(k-1) \quad [\text{para } k \geq 1]$$

Esta es una recurrencia lineal de primer orden. Con $\gamma(0)$ como condición inicial:

$$\gamma(k) = 0.6^k \cdot \gamma(0)$$

Dividiendo por $\gamma(0)$:

$$\rho(k) = \gamma(k)/\gamma(0) = 0.6^k \quad \text{para } k \geq 0. \quad \blacksquare$$

💡 *Esto muestra el decaimiento exponencial característico de la ACF de un AR(1) con coeficiente positivo.*

(d) Patrones de ACF y PACF para identificación de modelos

La siguiente tabla resume los patrones clave:

Proceso	ACF ($\rho(k)$)	PACF ($\alpha(k)$)	Interpretación
AR(1), $\varphi > 0$	Decaimiento exponencial positivo: $\rho(k) = \varphi^k$	Corte abrupto en k=1; $\alpha(1)=\varphi$, $\alpha(k)\approx 0$ para k>1	El proceso 'recuerda' el pasado inmediato
MA(1), $\theta > 0$	Corte abrupto: $\rho(1)\neq 0$, $\rho(k)=0$ para k>1	Decaimiento exponencial en todos los rezagos	Innovación de sólo 1 rezago
Ruido Blanco	$\rho(k) \approx 0$ para todo $k \geq 1$	$\alpha(k) \approx 0$ para todo $k \geq 1$	Sin estructura temporal
ARMA(p,q)	Ambas decaen sin corte abrupto	Ambas decaen sin corte abrupto	Requiere criterios AIC/BIC

¿Por qué sirven para identificar el orden?

- La PACF del AR(p) se 'corta' en el rezago p porque mide la correlación de Y_t con Y_{t-k} eliminando el efecto de los intermedios. Para k > p ese efecto es exactamente cero.
- La ACF del MA(q) se 'corta' en q porque el proceso sólo tiene memoria de q periodos de innovación.
- Este diagnóstico visual (correlogramas) es la primera etapa del procedimiento de Box-Jenkins.

Ejercicio 1.2 — Procesos AR, MA y ARMA

(a) AR(2): raíces del polinomio característico y estacionariedad

Modelo: $Y_t = 1.2Y_{t-1} - 0.32Y_{t-2} + \varepsilon_t$

El polinomio AR en el operador de rezago B es:

$$\Phi(z) = 1 - 1.2z + 0.32z^2$$

Para encontrar las raíces, igualamos $\Phi(z) = 0$:

$$0.32z^2 - 1.2z + 1 = 0$$

Aplicamos la fórmula cuadrática con a = 0.32, b = −1.2, c = 1:

$$\Delta = (-1.2)^2 - 4(0.32)(1) = 1.44 - 1.28 = 0.16$$

$$z = (1.2 \pm \sqrt{0.16}) / (2 \times 0.32) = (1.2 \pm 0.4) / 0.64$$

Las dos raíces son:

$$z_1 = (1.2 + 0.4) / 0.64 = 1.6 / 0.64 = 2.5$$

$$z_2 = (1.2 - 0.4) / 0.64 = 0.8 / 0.64 = 1.25$$

Condición de estacionariedad: las raíces de $\Phi(z)$ deben estar fuera del círculo unitario, es decir, $|z| > 1$.

- $|z_1| = 2.5 > 1$ ✓
- $|z_2| = 1.25 > 1$ ✓

✓ **Ambas raíces están fuera del círculo unitario → el AR(2) es ESTACIONARIO.**

💡 *Equivalentemente, las raíces del polinomio en términos del coeficiente AR ($\Phi(L^{-1}) = 0$) deben estar dentro del círculo unitario: 1/2.5=0.4 y 1/1.25=0.8, ambas con módulo menor a 1.* ✓

(b) MA(2): varianzas y covarianzas

Modelo: $Y_t = \varepsilon_t + 0.5\varepsilon_{t-1} - 0.3\varepsilon_{t-2}$ con $\varepsilon_t \sim WN(0, \sigma^2)$

$Var(Y_t)$:

Como los ε_t son no correlacionados:

$$Var(Y_t) = (1^2 + 0.5^2 + (-0.3)^2)\cdot\sigma^2 = (1 + 0.25 + 0.09)\cdot\sigma^2$$

✓ **$Var(Y_t) = 1.34\ \sigma^2$**

$Cov(Y_t, Y_{t-1}) = \gamma(1)$:

$$\gamma(1) = E[Y_tY_{t-1}] = E[(\varepsilon_t+0.5\varepsilon_{t-1}-0.3\varepsilon_{t-2})(\varepsilon_{t-1}+0.5\varepsilon_{t-2}-0.3\varepsilon_{t-3})]$$

Sólo sobreviven los productos del mismo índice ($E[\varepsilon_t\varepsilon_s]=\sigma^2\cdot 1\{t=s\}$):

$$\gamma(1) = (0.5\cdot 1 + (-0.3)\cdot 0.5)\cdot\sigma^2 = (0.5 - 0.15)\cdot\sigma^2$$

✓ **$Cov(Y_t, Y_{t-1}) = 0.35\ \sigma^2$**

$Cov(Y_t, Y_{t-2}) = \gamma(2)$:

$$\gamma(2) = (-0.3\cdot 1)\cdot\sigma^2 = -0.3\sigma^2$$

✓ **$Cov(Y_t, Y_{t-2}) = -0.3\ \sigma^2$**

$Cov(Y_t, Y_{t-k})$ para $k \geq 3$:

Para $|k| > q = 2$, no existen términos de ε con el mismo índice en Y_t y Y_{t-k}:

✓ **$Cov(Y_t, Y_{t-k}) = 0$ para $k \geq 3$ (propiedad de memoria finita del MA(q))**

(c) Condición de invertibilidad del MA(q)

Un proceso MA(q): $Y_t = \Theta(B)\varepsilon_t = (1 + \theta_1 B + \ldots + \theta_qB^q)\varepsilon_t$ es invertible si y sólo si las raíces del polinomio $\Theta(z)$ están todas fuera del círculo unitario: $|z_j| > 1$ para todo j.

Importancia para el pronóstico:

- Un MA(q) invertible admite una representación AR(∞) convergente: $\varepsilon_t = \Pi(B)Y_t = \Sigma_j \pi_j Y_{t-j}$ con $\Sigma|\pi_j| < \infty$.
- Esto significa que podemos expresar el error (y por ende el pronóstico) en términos del historial observable $Y_t, Y_{t-1}, \ldots$
- Si el MA no fuera invertible, existirían dos procesos MA con la misma ACF (problema de identificación) y no podríamos estimar ε_t de forma consistente a partir de los datos.

💡 *Ejemplo: MA(1) $Y_t = \varepsilon_t + \theta\varepsilon_{t-1}$ es invertible iff $|\theta| < 1$. Si $\theta = 2$, la raíz de $1+2z=0$ es $z=-1/2$, que tiene $|z|<1 \rightarrow$ no invertible.*

(d) Representación MA(∞) del AR(1) estacionario

Sea $Y_t = \varphi Y_{t-1} + \varepsilon_t$ con $|\varphi| < 1$. Queremos demostrar que $Y_t = \Sigma_{j=0}^{\infty} \varphi^j \varepsilon_{t-j}$.

Demostración por sustitución recursiva:

$$Y_t = \varphi Y_{t-1} + \varepsilon_t$$

$$= \varphi(\varphi Y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \varphi^2 Y_{t-2} + \varphi\varepsilon_{t-1} + \varepsilon_t$$

$$= \varphi^2(\varphi Y_{t-3} + \varepsilon_{t-2}) + \varphi\varepsilon_{t-1} + \varepsilon_t = \varphi^3 Y_{t-3} + \varphi^2\varepsilon_{t-2} + \varphi\varepsilon_{t-1} + \varepsilon_t$$

Iterando n pasos:

$$Y_t = \varphi^n Y_{t-n} + \Sigma_{j=0}^{n-1} \varphi^j \varepsilon_{t-j}$$

Cuando $n \rightarrow \infty$, dado que $|\varphi| < 1$, el proceso es estacionario con $Var(Y_t) = \sigma^2/(1-\varphi^2)$ finita, lo que implica que $\varphi^n Y_{t-n} \rightarrow 0$ en media cuadrática. Por tanto:

$$Y_t = \Sigma_{j=0}^{\infty} \varphi^j \varepsilon_{t-j}$$

La serie converge en media cuadrática porque $\Sigma_{j=0}^{\infty} \varphi^{2j} = 1/(1-\varphi^2) < \infty$ para $|\varphi| < 1$. ■

✓ **Interpretación: el valor actual Y_t es un promedio ponderado de todos los shocks pasados, con pesos que decaen exponencialmente.**

Ejercicio 1.3 — Raíces unitarias y prueba de Dickey-Fuller

(a) La caminata aleatoria no es estacionaria

Modelo: $Y_t = Y_{t-1} + \varepsilon_t$ (caminata aleatoria con $Y_0 = 0$)

Por sustitución recursiva desde $Y_0 = 0$:

$$Y_t = Y_0 + \Sigma_{s=1}^{t} \varepsilon_s = \Sigma_{s=1}^{t} \varepsilon_s$$

Cálculo de $Var(Y_t)$:

$$Var(Y_t) = Var(\Sigma_{s=1}^{t} \varepsilon_s) = \Sigma_{s=1}^{t} Var(\varepsilon_s) \quad \text{[no correlación del WN]}$$

$$Var(Y_t) = t \cdot \sigma^2$$

✓ **$Var(Y_t) = t\sigma^2$ → crece sin límite con t → NO estacionaria.**

Cálculo de $Cov(Y_t, Y_s)$ para $s \leq t$:

$$Cov(Y_t, Y_s) = Cov(\Sigma_{i=1}^{t} \varepsilon_i, \Sigma_{j=1}^{s} \varepsilon_j) = \Sigma_{i=1}^{t} \Sigma_{j=1}^{s} Cov(\varepsilon_i, \varepsilon_j)$$

Sólo los términos con i=j contribuyen (WN no correlacionado):

$$Cov(Y_t, Y_s) = \min(s,t) \cdot \sigma^2 \quad (\text{para } s \leq t, \text{ esto es } s \cdot \sigma^2)$$

✓ **La covarianza depende de t y s, no sólo de t−s → confirma no estacionariedad.**

(b) La primera diferencia es ruido blanco

$$\Delta Y_t = Y_t - Y_{t-1} = (Y_{t-1} + \varepsilon_t) - Y_{t-1} = \varepsilon_t$$

✓ **$\Delta Y_t = \varepsilon_t \sim WN(0, \sigma^2)$ → la primera diferencia es estacionaria (proceso I(0)).**

Esto ilustra el concepto de integración de orden 1: se dice que $Y_t \sim I(1)$ porque una diferenciación es suficiente para hacerlo estacionario.

(c) Por qué el estadístico ADF no sigue distribución t clásica

La prueba ADF contrasta H_0: $\delta = 0$ en el modelo:

$$\Delta Y_t = \mu + \delta Y_{t-1} + \Sigma_{j=1}^{k} \psi_j \Delta Y_{t-j} + \varepsilon_t$$

Bajo H_0 ($\delta=0$), Y_t es una caminata aleatoria. El regresor clave Y_{t-1} tiene varianza que crece con t (es O(t)), es decir, es no estacionario.

El teorema central del límite clásico requiere que los regresores sean estacionarios (varianza finita). Cuando el regresor es I(1):

- Las sumas parciales ΣY_{t-1} convergen a integrales estocásticas de movimiento Browniano (funcionales del proceso de Wiener W(r)).
- El estadístico $\hat{\delta}/SE(\hat{\delta})$ converge a una distribución Dickey-Fuller (no normal ni t clásica).
- Esta distribución tiene colas más pesadas hacia la izquierda que la t clásica → se necesitan valores críticos especiales tabulados por Dickey y Fuller.

💡 *Si usáramos valores críticos de la distribución t estándar, tendríamos tamaño excesivo (rechazaríamos H_0 con más frecuencia de la nominal), lo cual llevaría a conclusiones incorrectas sobre estacionariedad.*

(d) Log-precios I(1) y log-retornos I(0) en finanzas

En la práctica financiera:

- Log-precios: $p_t = \log(P_t)$ típicamente siguen una caminata aleatoria → I(1). La prueba ADF no rechaza H_0 de raíz unitaria. No son predecibles (hipótesis de mercados eficientes en su forma débil).
- Log-retornos: $r_t = \Delta p_t = p_t - p_{t-1} = \log(P_t/P_{t-1})$ → I(0). Son estacionarios (en media y varianza, al menos como primera aproximación).

Implicaciones para el modelado:

- Para pronóstico de precios: se modela Δp_t (los retornos) con ARIMA y se acumula hacia adelante → $\hat{Y}_{t+h} = Y_t + \Sigma\, \Delta\hat{y}_{t+j}$.
- Regresión de p_t sobre p_{x_t} (dos I(1)) sin cointegración produce regresión espuria: R^2 alto, estadísticos t grandes, pero la relación es ficticia.
- Si hay cointegración entre log-precios, existe una relación de equilibrio de largo plazo que sí es real y modelable (ej. pairs trading).

SECCIÓN 2 — Modelos ARIMA(p, d, q)

Ejercicio 2.1 — Identificación, Estimación y Diagnóstico

(a) Identificación del orden según patrones de ACF y PACF

Caso	Patrón ACF	Patrón PACF	Modelo identificado
(i)	Decaimiento exponencial	Corte abrupto en rezago 2	AR(2) — PACF corta en p=2
(ii)	Corte abrupto en rezago 1	Decaimiento exponencial	MA(1) — ACF corta en q=1
(iii)	Decaimiento sin corte	Decaimiento sin corte	ARMA(p,q) — ambas decaen
(iv)	Pico en k=1, ~0 después	Decaimiento exponencial	MA(1) — caso especial de (ii)

💡 *El caso (iv) es idéntico al (ii): un MA(1) tiene exactamente un pico en la ACF (k=1) y luego es cero. La PACF decae exponencialmente porque la representación AR(∞) involucra infinitos rezagos.*

(b) Criterios AIC y BIC

```
AIC = −2 log L̂ + 2k
BIC = −2 log L̂ + k·log(n)
```

donde $\hat{L}$ es la verosimilitud maximizada, k el número de parámetros y n el tamaño de muestra.

Criterio	Penalización	Cuándo usar	Comportamiento
AIC	2k	Pronóstico, modelos grandes	Puede sobreajustar con n grande
BIC	k·log(n)	Identificación del 'verdadero' modelo	Más parsimonioso para n > 7

BIC penaliza más la complejidad cuando $\log(n) > 2$, es decir, cuando $n > e^2 \approx 7.39$. En la práctica financiera con n en decenas o cientos, BIC siempre penaliza más y selecciona modelos más parsimoniosos.

💡 *En ambos casos, se prefiere el modelo con menor valor del criterio. Si AIC y BIC eligen órdenes distintos, es señal de que el tamaño muestral puede no ser suficiente para discriminar entre los modelos.*

(c) Procedimiento de Box-Jenkins en tres etapas

Etapa 1 — Identificación

- Graficar la serie temporal Y_t en función del tiempo.
- Si la serie parece no estacionaria (tendencia, varianza creciente), aplicar diferencias ΔY_t o log-transformación.
- Aplicar prueba ADF para confirmar el orden de integración d.
- Graficar ACF y PACF de la serie (diferenciada si es necesario) para proponer p y q.

Etapa 2 — Estimación

- Estimar los parámetros ($\varphi_1,\ldots,\varphi_p$, $\theta_1,\ldots,\theta_q$, σ^2) por máxima verosimilitud (MV) o mínimos cuadrados condicionales.
- Comparar los modelos candidatos usando AIC y BIC.

Etapa 3 — Diagnóstico

- Calcular los residuos $\hat{\varepsilon}_t$ del modelo estimado.
- Graficar la ACF y PACF de los residuos: deben ser aproximadamente ruido blanco.
- Aplicar la prueba de Ljung-Box sobre los residuos.
- Si los residuos no son ruido blanco → revisar el orden del modelo y repetir desde la Etapa 1.

(d) Prueba de Ljung-Box para diagnóstico de residuos

El estadístico de Ljung-Box con h rezagos es:

$$Q = n(n+2) \cdot \Sigma_{k=1}^{h} \hat{\rho}^2(k)/(n-k)$$

donde n es el tamaño de muestra y $\hat{\rho}(k)$ es la autocorrelación muestral del residuo en el rezago k.

Bajo H_0 (los residuos son ruido blanco): $Q \sim \chi^2(h - p - q)$, es decir, chi-cuadrada con $h-p-q$ grados de libertad (descontamos los parámetros estimados).

Se rechaza H_0 (hay estructura no capturada) si $Q > \chi^2_{\alpha}(h-p-q)$.

Recomendación práctica: usar $h = \min(10, n/5)$. Esto balancea:

- Detectar dependencias hasta un horizonte razonable (no demasiado lejano).
- Mantener potencia estadística (demasiados rezagos reduce la potencia).

💡 *Si la prueba de Ljung-Box rechaza H_0, el modelo necesita más parámetros AR o MA. Si los residuos muestran heterocedasticidad condicional, puede ser necesario un modelo GARCH.*

Ejercicio 2.2 — ARIMA(1,1,1) para log-precios de una acción

(a) Conversión a ARMA(1,1) para los retornos

Modelo original para el log-precio $y_t = \log(P_t)$:

$$(1 - \varphi_1 B)(1 - B)y_t = (1 + \theta_1 B)\varepsilon_t$$

Definimos el log-retorno $r_t = \Delta y_t = y_t - y_{t-1}$. Entonces $(1-B)y_t = r_t$, y el modelo se convierte en:

$$(1 - \varphi_1 B)\ r_t = (1 + \theta_1 B)\varepsilon_t$$

Expandiendo:

$$r_t - \varphi_1 r_{t-1} = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

✓ **$r_t = \varphi_1 r_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ → ARMA(1,1) para los retornos r_t.**

(b) Cálculo del pronóstico $\hat{r}_{T+1|T}$

Con $\hat{\varphi}_1 = 0.15$ y $\hat{\theta}_1 = -0.08$, el pronóstico óptimo (mínimo ECM lineal) es la esperanza condicional:

$$\hat{r}_{T+1|T} = E[r_{T+1} \mid r_t, r_{t-1}, \ldots]$$

Del modelo ARMA(1,1): $r_{T+1} = \hat{\varphi}_1 r_t + \varepsilon_{T+1} + \hat{\theta}_1 \varepsilon_t$

Tomando esperanza condicional ($E[\varepsilon_{T+1}|\mathcal{F}_t] = 0$):

$$\hat{r}_{T+1|T} = \hat{\varphi}_1 \cdot r_t + \hat{\theta}_1 \cdot \varepsilon_t$$

Nota: en la práctica, el residuo $\varepsilon_t = r_t - \hat{r}_{t|t-1}$ se calcula recursivamente durante la estimación. El enunciado escribe la fórmula con dos términos de error para reflejar la estructura completa:

$$\hat{r}_{T+1|T} = \hat{\varphi}_1 \cdot r_t + \hat{\varphi}_1 \cdot \hat{\theta}_1 \cdot \varepsilon_{T-1} + \hat{\theta}_1 \cdot \varepsilon_t$$

💡 *El pronóstico depende tanto del retorno observado r_t como del residuo estimado ε_t del modelo. Esto distingue al ARMA del AR puro.*

(c) Intervalo de predicción al 95% y traducción a precio

El intervalo de predicción al 95% para el retorno r_{T+1} es:

$$\hat{r}_{T+1|T} \pm 1.96 \cdot \hat{\sigma}$$

donde $\hat{\sigma}$ es la desviación estándar estimada del ruido blanco.

Traducción al precio $P_{T+1} = P_t \cdot \exp(r_{T+1})$:

$$IC_{95\%}(P_{T+1}) = [\ P_t \cdot \exp(\hat{r}_{T+1|T} - 1.96\hat{\sigma}),\ \ P_t \cdot \exp(\hat{r}_{T+1|T} + 1.96\hat{\sigma})\ ]$$

💡 *La transformación exponencial es no lineal, por lo que el intervalo para el precio no es simétrico. Es asimétrico en niveles: el límite superior está más alejado del pronóstico central que el límite inferior, lo cual es consistente con la distribución log-normal del precio.*

(d) ¿Captura el ARIMA(1,1,1) la asimetría en volatilidad?

No. El ARIMA(1,1,1) modela la dinámica de la media condicional, pero asume varianza condicional constante σ^2. El efecto de asimetría en volatilidad (también llamado efecto apalancamiento o leverage effect) se refiere a que:

- Caídas del mercado (retornos negativos) generan más volatilidad que subidas de la misma magnitud.
- Esto implica que Var(r_{t+1} | r_t < 0) > Var(r_{t+1} | r_t > 0), una heterocedasticidad condicional asimétrica.

Para capturar este efecto se necesita extender el modelo con componentes de varianza condicional:

- GARCH(1,1): modela la varianza condicional como $\sigma^2_t = \omega + \alpha\varepsilon^2_{t-1} + \beta\sigma^2_{t-1}$.
- GJR-GARCH o EGARCH: añaden términos asimétricos para diferenciar entre shocks positivos y negativos.
- ARIMA-GARCH: combinan la dinámica de la media (ARIMA) con la de la varianza (GARCH).

Ejercicio 2.3 — Pronóstico con ARIMA(2,1,0) y horizonte múltiple

Modelo: $(1 - \varphi_1 B - \varphi_2 B^2)(1-B)Y_t = \varepsilon_t$ con $\varphi_1=0.5$, $\varphi_2=-0.2$, $\sigma^2=1$.

(a) Ecuación del AR(2) para $W_t = \Delta Y_t$

Definimos $W_t = \Delta Y_t = Y_t - Y_{t-1}$. El modelo se convierte en:

$$(1 - 0.5B + 0.2B^2)W_t = \varepsilon_t$$

Expandiendo el operador de rezago:

$$W_t - 0.5W_{t-1} + 0.2W_{t-2} = \varepsilon_t$$

✓ **$W_t = 0.5W_{t-1} - 0.2W_{t-2} + \varepsilon_t$ (AR(2) para los incrementos)**

(b) Pronósticos $\hat{W}_{T+1|T}$ y $\hat{W}_{T+2|T}$

Datos: $Y_t = 100$, $W_t = \Delta Y_t = 1.2$, $W_{t-1} = 0.8$.

Pronóstico a horizonte h=1:

$$\hat{W}_{T+1|T} = 0.5 \cdot W_t - 0.2 \cdot W_{t-1} + E[\varepsilon_{T+1}|\mathcal{F}_t]$$

$$\hat{W}_{T+1|T} = 0.5 \cdot (1.2) - 0.2 \cdot (0.8) + 0$$

$$\hat{W}_{T+1|T} = 0.60 - 0.16 = 0.44$$

✓ **$\hat{W}_{T+1|T} = 0.44 \rightarrow \hat{Y}_{T+1|T} = Y_t + \hat{W}_{T+1|T} = 100 + 0.44 = 100.44$**

Pronóstico a horizonte h=2:

Usamos $\hat{W}_{T+1|T}$ como si fuera el valor observado (esperanza condicional) y $E[\varepsilon_{T+2}|\mathcal{F}_t]=0$:

$$\hat{W}_{T+2|T} = 0.5 \cdot \hat{W}_{T+1|T} - 0.2 \cdot W_t$$

$$\hat{W}_{T+2|T} = 0.5 \cdot (0.44) - 0.2 \cdot (1.2) = 0.22 - 0.24 = -0.02$$

✓ **$\hat{W}_{T+2|T} = -0.02 \rightarrow \hat{Y}_{T+2|T} = \hat{Y}_{T+1|T} + \hat{W}_{T+2|T} = 100.44 - 0.02 = 100.42$**

(c) ECM de predicción y coeficientes ψ_j

Los coeficientes de la representación MA(∞) del AR(2): $W_t = \Sigma_j \psi_j \varepsilon_{t-j}$ satisfacen:

$$\psi_0 = 1, \quad \psi_1 = \varphi_1 = 0.5, \quad \psi_j = \varphi_1 \psi_{j-1} + \varphi_2 \psi_{j-2} \quad \text{para } j \geq 2$$

Calculamos ψ_2:

$$\psi_2 = \varphi_1 \cdot \psi_1 + \varphi_2 \cdot \psi_0 = 0.5 \cdot (0.5) + (-0.2) \cdot (1) = 0.25 - 0.20 = 0.05$$

✓ **$\psi_0 = 1$, $\psi_1 = 0.5$, $\psi_2 = 0.05$**

El ECM a horizonte h es:

$$MSE_h = \sigma^2 \cdot \Sigma_{j=0}^{h-1} \psi^2_j$$

$$MSE_1 = \sigma^2 \cdot \psi_0^2 = 1 \cdot 1 = 1$$

$$MSE_2 = \sigma^2 \cdot (\psi_0^2 + \psi_1^2) = 1 \cdot (1 + 0.25) = 1.25$$

(d) Intervalos de predicción al 95%

Intervalo para W_{T+1} y W_{T+2}:

```
IC_{95%}(W_{T+h}) = Ŵ_{T+h|T} ± 1.96·√(MSE_h)
IC_{95%}(W_{T+1}) = 0.44 ± 1.96·√1 = 0.44 ± 1.96  →  [-1.52,  2.40]
IC_{95%}(W_{T+2}) = -0.02 ± 1.96·√1.25 = -0.02 ± 2.19  →  [-2.21,  2.17]
```

Traducción a Y_{T+h} = $Y_t + \Sigma_{j=1}^{h}$ W_{T+j}:

```
IC_{95%}(Y_{T+1}) = [100-1.52,  100+2.40] = [98.48,  102.40]
IC_{95%}(Y_{T+2}) = [100+(0.44-1.52)+(-0.02-2.19),  ...] ≈ [96.71,
                                                        104.11]
```

💡 *Para Y_{T+2} el intervalo se amplía porque acumula la incertidumbre de W_{T+1} y W_{T+2} conjuntamente. En general, los intervalos crecen con el horizonte.*

Ejercicio 2.4 — Cointegración y Spreads Estadísticos

(a) Teorema de Representación de Granger

Si Y_t y X_t son ambas I(1) y están cointegradas con vector (1, −β), entonces existe un Modelo de Corrección de Error (ECM):

$$\Delta Y_t = \alpha(Y_{t-1} - \beta X_{t-1}) + \Sigma_j \gamma_j \Delta Y_{t-j} + \Sigma_j \delta_j \Delta X_{t-j} + \varepsilon_t$$

Interpretación del término de corrección $\alpha(Y_{t-1} - \beta X_{t-1})$:

- La expresión $Z_{t-1} = Y_{t-1} - \beta X_{t-1}$ es el spread o desequilibrio de largo plazo del periodo anterior.
- Si $Z_{t-1} > 0$ (Y_{t-1} está por encima de su valor de equilibrio βX_{t-1}), el coeficiente $\alpha < 0$ implica ΔY_t negativo → Y_t se corrige a la baja para volver al equilibrio.
- La velocidad de ajuste $|\alpha|$ determina qué tan rápido el sistema regresa al equilibrio de largo plazo tras una perturbación.
- Los términos $\Sigma\gamma_j$ y $\Sigma\delta_j$ capturan la dinámica de corto plazo (cambios pasados de ambas series).

💡 *El teorema de Granger establece que cointegración ⟺ existe una representación ECM válida. Es un resultado de equivalencia fundamental en econometría de series de tiempo.*

(b) Estimación de β y prueba de Engle-Granger

Procedimiento de Engle-Granger en dos etapas:

Etapa 1 — Estimar β por MCO en la regresión de largo plazo:

$$Y_t = \alpha_0 + \beta X_t + u_t \quad \rightarrow \quad \hat{\beta} = (\Sigma X_t Y_t - n \cdot \bar{X} \cdot \bar{Y}) / (\Sigma X_t^2 - n \cdot \bar{X}^2)$$

MCO es super-consistente: converge a β a una tasa √n más rápida que en el caso estacionario.

Etapa 2 — Probar si los residuos $\hat{Z}_t = Y_t - \beta X_t$ son I(0):

Aplicar la prueba ADF a $\hat{Z}_t$. Se rechaza H_0 (raíz unitaria en los residuos) si el estadístico ADF es suficientemente negativo. Los valores críticos son distintos a los de la ADF estándar (se usan las tablas de Engle-Granger porque β fue estimado).

- Si se rechaza H_0: $\hat{Z}_t \sim I(0)$ → hay cointegración → se puede hacer pairs trading.
- Si no se rechaza: no hay cointegración → la relación es espuria.

(c) Spread AR(1): media, varianza y tiempo de retorno

Modelo: $Z_t = \mu + \varphi Z_{t-1} + \varepsilon_t$ con $|\varphi| < 1$ y $\varepsilon_t \sim WN(0, \sigma^2)$.

Media incondicional:

$$E[Z_t] = \mu + \varphi \cdot E[Z_{t-1}] = \mu/(1-\varphi)$$

Varianza incondicional:

$$Var(Z_t) = \sigma^2/(1-\varphi^2)$$

Tiempo esperado de retorno a la media $E[\tau_\mu]$:

Para un proceso AR(1) estacionario, el tiempo esperado para que el spread regrese a su media desde un punto z_0 es aproximadamente:

$$E[\tau_\mu] \approx 1/(1-\varphi) \quad \text{periodos (en sentido de autocorrelación)}$$

Intuitivamente: cuanto más cercano a 1 sea φ (proceso muy persistente), mayor el tiempo de retorno. Cuanto más pequeño φ, más rápido el spread vuelve a μ.

(d) Aplicación: φ=0.95, μ=0, σ=0.01

$$E[Z_t] = 0/(1-0.95) = 0$$

$$Var(Z_t) = (0.01)^2/(1-0.95^2) = 0.0001/0.0975 \approx 0.001026$$

$$\text{Desv. Est.}(Z_t) = \sqrt{0.001026} \approx 0.03203$$

$$E[\tau_\mu] \approx 1/(1-0.95) = 20 \text{ periodos}$$

Regla de apertura de la posición de arbitraje:

- Se abre posición cuando el spread está suficientemente alejado de la media: $|Z_t| > c \cdot \text{Desv.Est.}(Z_t)$, típicamente c = 1 o c = 2.
- Con c=2: se abre si $|Z_t| > 2 \cdot 0.032 \approx 0.064$.
- Si $Z_t > 0.064$: vender Y, comprar X (spread revertirá hacia 0).
- Si $Z_t < -0.064$: comprar Y, vender X.
- Con φ=0.95 el spread es muy persistente (E[τ]=20 periodos), lo cual es favorable para pairs trading ya que hay tiempo suficiente para que la posición sea rentable.

SECCIÓN 3 — Modelos SARIMA y Estacionalidad

Ejercicio 3.1 — Estructura y notación del SARIMA

(a) SARIMA(1,1,1)(1,1,1)$_{12}$ — Expansión completa

La notación general es:

$$\Phi_P(B^s)\cdot\varphi_p(B)\cdot(1-B^s)^D\cdot(1-B)^d\cdot Y_t = \Theta_Q(B^s)\cdot\theta_q(B)\cdot\varepsilon_t$$

Para SARIMA(1,1,1)(1,1,1)$_{12}$ con s=12:

- Parte regular AR(1): $\varphi(B) = 1 - \varphi_1 B$
- Parte estacional AR(1): $\Phi(B^{12}) = 1 - \Phi_1 B^{12}$
- Diferencia regular (d=1): $(1-B)$
- Diferencia estacional (D=1): $(1-B^{12})$
- Parte regular MA(1): $\theta(B) = 1 + \theta_1 B$
- Parte estacional MA(1): $\Theta(B^{12}) = 1 + \Theta_1 B^{12}$

El modelo completo expandido es:

$$(1-\Phi_1 B^{12})(1-\varphi_1 B)(1-B^{12})(1-B)Y_t = (1+\Theta_1 B^{12})(1+\theta_1 B)\varepsilon_t$$

💡 *Este modelo tiene 4 parámetros a estimar: φ_1 (AR regular), Φ_1 (AR estacional), θ_1 (MA regular), Θ_1 (MA estacional), además de σ^2.*

(b) Expansión de $\Delta_{12}(\Delta_1 Y_t)$

Calculamos paso a paso aplicando los operadores:

Paso 1 — Diferencia regular:

$$\Delta Y_t = (1-B)Y_t = Y_t - Y_{t-1}$$

Paso 2 — Diferencia estacional aplicada al resultado anterior:

$$\begin{aligned}\Delta_{12}(\Delta Y_t) &= (1-B^{12})(\Delta Y_t) = \Delta Y_t - \Delta Y_{t-12}\\ &= (Y_t - Y_{t-1}) - (Y_{t-12} - Y_{t-13})\\ &= Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}\end{aligned}$$

✓ **$\Delta_{12}(\Delta_1 Y_t) = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$**

Involucra exactamente los rezagos 0, 1, 12 y 13. Esto significa que para poder calcular esta diferencia doble, se necesitan al menos 13 observaciones pasadas.

(c) Patrones de ACF/PACF y necesidad de diferenciación estacional

Antes de aplicar Δ_{12}:

- La ACF muestral presenta picos significativos en los rezagos s=12, 2s=24, 3s=36, … que no decaen rápidamente.
- $\rho(12)$, $\rho(24)$, $\rho(36)$ son todos grandes y estadísticamente significativos (fuera de las bandas $\pm 1.96/\sqrt{T}$).
- Esta persistencia indica que la media del proceso cambia con el ciclo estacional → hay estacionalidad determinista o estocástica no removida.

Después de aplicar Δ_{12}:

- Los picos en rezagos múltiplos de 12 desaparecen (o se reducen significativamente).
- $\rho(12)$, $\rho(24)$, $\rho(36)$ caen dentro de las bandas de significancia.
- La serie diferenciada se ve más estacionaria en el sentido de covarianza.

💡 *Analogía con la raíz unitaria regular: así como $\Delta Y_t = Y_t - Y_{t-1}$ elimina la tendencia (raíz unitaria en $z=1$), $\Delta_{12} Y_t = Y_t - Y_{t-12}$ elimina la raíz unitaria estacional en $z^{12}=1$.*

(d) Elección de (d, D) para datos de ventas mensuales

Criterios para d (diferenciación regular):

- $d=1$ si la serie tiene tendencia estocástica (raíz unitaria). La prueba ADF en la serie original no rechaza H_0.
- $d=0$ si la serie es estacionaria en torno a una media fija (o tras desestacionalización).
- Rara vez $d>1$ en la práctica (implica doblar la varianza de los errores de pronóstico).

Criterios para D (diferenciación estacional):

- $D=1$ si la ACF de la serie (posiblemente con $d=1$) aún muestra picos persistentes en múltiplos de 12.
- $D=0$ si la estacionalidad es determinista y se puede capturar con variables dummy o efectos fijos.
- $D>1$ es casi nunca necesario (se produce sobrediferenciación).

Combinación típica para ventas mensuales: ($d=1$, $D=1$). Justificación:

- Las ventas suelen tener tendencia creciente → $d=1$ elimina la raíz unitaria regular.
- La estacionalidad varía año con año (por ejemplo, la temporada navideña crece) → $D=1$ maneja la raíz unitaria estacional.
- Esta es exactamente la estructura del modelo de Airline (SARIMA$(0,1,1)(0,1,1)_{12}$), el modelo de Box-Jenkins más famoso en aplicaciones de negocios.

Ejercicio 3.2 — Modelo de Airline para ventas mensuales

Modelo: SARIMA(0,1,1)(0,1,1)$_{12}$ para V_t:

$$(1-B)(1-B^{12})V_t = (1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t$$

(a) Expansión del lado izquierdo

Aplicamos los operadores de diferencia al lado izquierdo:

$$\begin{aligned}(1-B)(1-B^{12})V_t &= (1 - B^{12} - B + B^{13})V_t \\ &= V_t - B^{12}V_t - BV_t + B^{13}V_t \\ &= V_t - V_{t-12} - V_{t-1} + V_{t-13}\end{aligned}$$

✓ **LHS = $V_t - V_{t-1} - V_{t-12} + V_{t-13}$** ■

(b) Expansión del lado derecho y ecuación completa

Expandimos el producto de los dos operadores MA:

$$\begin{aligned}(1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t &= \varepsilon_t + \Theta_1 B^{12}\varepsilon_t + \theta_1 B\varepsilon_t + \theta_1\Theta_1 B^{13}\varepsilon_t \\ &= \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}\end{aligned}$$

Igualando LHS = RHS, la ecuación completa del modelo es:

$$V_t - V_{t-1} - V_{t-12} + V_{t-13} = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$$

Despejando V_t:

$$V_t = V_{t-1} + V_{t-12} - V_{t-13} + \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$$

💡 *Interpretación: el pronóstico de este mes depende del mes anterior (tendencia), del mismo mes del año pasado (estacionalidad) y su diferencia (corrección). Más los shocks de innovación recientes.*

(c) Cálculo del pronóstico $\hat{V}_{61}$

Parámetros estimados: $\hat{\theta}_1 = -0.4$, $\hat{\Theta}_1 = -0.6$.

Datos disponibles: $V_{60}=50$, $V_{59}=45$, $V_{48}=40$, $V_{47}=35$, $\hat{\varepsilon}_{60}=2$, $\hat{\varepsilon}_{48}=1$.

El pronóstico óptimo es $E[V_{61} \mid \mathcal{F}_{60}]$:

$$\hat{V}_{61} = V_{60} + V_{48} - V_{47} + \hat{\theta}_1\cdot\hat{\varepsilon}_{60} + \hat{\Theta}_1\cdot\hat{\varepsilon}_{48} + \hat{\theta}_1\hat{\Theta}_1\cdot\hat{\varepsilon}_{47}$$

Nota: $\hat{\varepsilon}_{47}$ es el residuo del período 47. Si no se proporciona, asumimos $\hat{\varepsilon}_{47}\approx 0$ (o que los errores más lejanos son despreciables). El término $E[\varepsilon_{61}|\mathcal{F}_{60}]=0$.

Calculando cada término:

$$\begin{aligned}V_{60} + V_{48} - V_{47} &= 50 + 40 - 35 = 55 \\ \hat{\theta}_1\cdot\hat{\varepsilon}_{60} &= (-0.4)\cdot(2) = -0.8 \\ \hat{\Theta}_1\cdot\hat{\varepsilon}_{48} &= (-0.6)\cdot(1) = -0.6 \\ \hat{\theta}_1\hat{\Theta}_1\cdot\hat{\varepsilon}_{47} &\approx (-0.4)(-0.6)\cdot 0 = 0 \quad [\text{asumiendo } \hat{\varepsilon}_{47} \approx 0] \\ \hat{V}_{61} &= 55 - 0.8 - 0.6 + 0 = 53.6\end{aligned}$$

✓ **$\hat{V}_{61}$ = 53.6 millones MXN**

(d) Intervalos de predicción para V_{61} y V_{73} — por qué crecen con el horizonte

Intervalo para V_{61} (horizonte h=1):

Para h=1, el único error es ε_{61}, y el $MSE_1 = \sigma^2 \cdot \psi_0^2 = \sigma^2$.

$$IC_{95\%}(V_{61}) = \hat{V}_{61} \pm 1.96 \cdot \hat{\sigma} = 53.6 \pm 1.96 \cdot \hat{\sigma}$$

Intervalo para V_{73} (horizonte h=13, mismo mes del año siguiente):

Para h=13, el intervalo es mucho más amplio porque la varianza del error de predicción es:

$$MSE_{13} = \sigma^2 \cdot \Sigma_{j=0}^{12} \psi_j^2 \quad \text{(suma de 13 coeficientes al cuadrado)}$$

$$IC_{95\%}(V_{73}) = \hat{V}_{73} \pm 1.96 \cdot \sqrt{(MSE_{13})} = \hat{V}_{73} \pm 1.96 \cdot \hat{\sigma} \cdot \sqrt{(\Sigma \psi_j^2)}$$

¿Por qué el intervalo crece con el horizonte?

- Al pronosticar h pasos adelante, se acumulan los errores de los shocks ε_{T+1}, ε_{T+2}, …, ε_{T+h}, cada uno desconocido.
- Matemáticamente: $Y_{T+h} - \hat{Y}_{T+h|T} = \Sigma_{j=0}^{h-1} \psi_j \cdot \varepsilon_{T+h-j}$, y la varianza de esta suma crece con h.
- En el modelo de Airline, los ψ_j no decaen a cero rápidamente (por las raíces unitarias), por lo que el fan chart se abre indefinidamente → incertidumbre ilimitada a largo plazo.

💡 *Esta es una propiedad fundamental: los modelos ARIMA con d≥1 o D≥1 tienen intervalos de predicción que crecen sin límite (en contraste con los procesos estacionarios ARMA donde los intervalos convergen a la varianza incondicional).*

Ejercicio 3.3 — SARIMA para tasas CETES con ciclos trimestrales (s=13)

(a) Propuesta de modelo SARIMA y justificación

La tasa de rendimiento de CETES a 28 días se registra semanalmente con un ciclo trimestral de s=13 semanas ligado al calendario fiscal. El ACF muestra picos en k=13, 26, 39, …

Modelo propuesto: SARIMA(1,1,0)(1,1,0)$_{13}$

$$(1-\Phi_1 B^{13})(1-\varphi_1 B)(1-B^{13})(1-B)Y_t = \varepsilon_t$$

Justificación de los órdenes:

- d=1: Las tasas de interés suelen ser I(1) (la prueba ADF no rechaza raíz unitaria). La primera diferencia $\Delta Y_t = Y_t - Y_{t-1}$ (cambio semanal en la tasa) es estacionaria.
- D=1: Los picos persistentes en ρ(13), ρ(26), ρ(39) de la ACF indican raíz unitaria estacional. Aplicar $\Delta_{13} Y_t = Y_t - Y_{t-13}$ elimina la estacionalidad estocástica.
- p=1 (AR regular): Después de las dos diferencias, la PACF de la serie doblemente diferenciada puede mostrar un pico significativo en el rezago 1, indicando AR(1) para la dinámica de corto plazo.
- P=1 (AR estacional): Si la PACF muestra un pico en el rezago 13 (pero decaimiento en 26, 39), se necesita un AR estacional de orden 1.
- q=0, Q=0: Si la ACF y PACF de los residuos son consistentes con ruido blanco sin necesitar términos MA, se adopta la especificación más parsimoniosa.

Patrones ACF/PACF que guían la selección:

Rezago	ACF antes de Δ_{13}	ACF después de Δ_{13}	Interpretación
k=13	Grande, significativo	Pequeño/no signif.	D=1 elimina raíz estacional
k=26	Grande, significativo	Pequeño/no signif.	Segundo armónico eliminado
k=39	Moderado	≈ 0	Tercer armónico eliminado
k=1	Posible pico	Posible pico	Indica AR(1) regular

💡 *Modelo alternativo: SARIMA(0,1,1)(0,1,1)$_{13}$ (tipo Airline adaptado al ciclo trimestral). Comparar con AIC y BIC para seleccionar entre los dos.*

(b) Pronóstico 4 semanas adelante e intervalos

Una vez estimados $\hat{\varphi}_1$ y $\hat{\Phi}_1$ por máxima verosimilitud, el pronóstico a horizonte h se obtiene por la ecuación de recurrencia hacia adelante.

La ecuación del modelo diferenciado $W_t = (1-B^{13})(1-B)Y_t$ satisface:

$$W_t = \hat{\varphi}_1 W_{t-1} + \hat{\Phi}_1 W_{t-13} - \hat{\varphi}_1 \hat{\Phi}_1 W_{t-14} + \varepsilon_t$$

Para h=1,2,3,4, el pronóstico condicional se calcula sustituyendo valores observados cuando están disponibles y pronósticos previos cuando no:

$$\hat{W}_{T+h|T} = \hat{\varphi}_1 \cdot \hat{W}_{T+h-1|T} + \hat{\Phi}_1 \cdot \hat{W}_{T+h-13|T} - \hat{\varphi}_1 \hat{\Phi}_1 \cdot \hat{W}_{T+h-14|T}$$

Para h≤13, $\hat{W}_{T+h-13|T} = W_{T+h-13}$ (observado), simplificando el cálculo.

Los coeficientes MA(∞) del modelo (ψ_j) se calculan por la fórmula recursiva y los intervalos al 80% y 95% son:

$$IC_{80\%}(Y_{t+h}) = \hat{Y}_{T+h|T} \pm 1.282 \cdot \hat{\sigma} \cdot \sqrt{\Sigma_{j=0}^{h-1} \psi_j^2}$$

$$IC_{95\%}(Y_{t+h}) = \hat{Y}_{T+h|T} \pm 1.960 \cdot \hat{\sigma} \cdot \sqrt{\Sigma_{j=0}^{h-1} \psi_j^2}$$

El intervalo al 80% es más angosto que el de 95%. En decisiones de trading de tasas, el intervalo más estrecho (80%) indica la zona de mayor certeza donde se concentran las decisiones operativas, mientras el 95% define los límites de riesgo extremo.

(c) Evaluación con ECMP y comparación de modelos

Se reservan las últimas 26 semanas como muestra de validación (fuera de muestra). Para cada horizonte h=1,…,26 se calcula el Error Cuadrático Medio de Predicción (ECMP):

$$ECMP = (1/26) \cdot \Sigma_t (Y_t - \hat{Y}_{t|t-h})^2$$

Modelo	Parámetros	AIC	ECMP fuera de muestra	Captura estacionalidad
ARIMA(1,1,0) sin estacional	1 (φ_1)	Menor	Generalmente mayor	No
SARIMA(1,1,0)(1,1,0)$_{13}$	2 (φ_1, Φ_1)	Puede ser mayor	Generalmente menor	Sí

El SARIMA debería mostrar menor ECMP fuera de muestra cuando la estacionalidad trimestral es real (no aleatoria), porque captura la estructura de los picos en rezagos 13, 26, 39.

Sin embargo, si los picos de ACF son artefactos de la muestra específica y no representan una dinámica real, el ARIMA simple podría ser preferible por parsimonia (menos riesgo de sobreajuste).

Regla práctica: si la diferencia de ECMP fuera de muestra entre los dos modelos es pequeña, preferir el modelo más parsimonioso (ARIMA simple). Si hay diferencia económicamente significativa, usar el SARIMA.

(d) Regla de decisión para trading de tasas y riesgos del modelo

Esquema de trading: el pronóstico de la tasa CETES en t+1 ayuda a decidir si comprar o vender futuros de CETES.

Regla de decisión basada en el intervalo de predicción:

- Si el límite inferior del IC al 95% de la tasa en t+1 es mayor que la tasa actual → se espera alza en la tasa → conviene vender futuros de bonos (precio del bono cae cuando la tasa sube).
- Si el límite superior del IC al 95% de la tasa en t+1 es menor que la tasa actual → se espera baja en la tasa → conviene comprar futuros de bonos.
- Si el intervalo de confianza contiene la tasa actual → no hay señal clara → no operar o reducir posición.

$$\text{Señal de venta: } LI_{95\%}(\hat{Y}_{T+1}) > Y_t$$

```
Señal de compra: LS95%(Ŷ_{T+1}) < Yt

Sin señal: LI95% ≤ Yt ≤ LS95%
```

Riesgos del modelo:

- Riesgo de especificación: el modelo asume que la estructura de la serie es estable. En México, cambios de política monetaria del Banxico (ej. ciclos de alza/baja de tasas) pueden romper la estructura del modelo.
- Riesgo de estimación: con muestras pequeñas, los parámetros $\hat{\varphi}_1$ y $\hat{\Phi}_1$ tienen error estándar alto. El sesgo hacia abajo del estimador Yule-Walker puede subestimar la persistencia real.
- Riesgo de eventos extremos: el modelo asume distribución normal de los errores. Eventos como crisis financieras o decisiones inesperadas de política monetaria generan outliers que el modelo no puede anticipar.
- Riesgo de modelo incorrecto: si el verdadero proceso no tiene exactamente s=13 semanas de ciclo (por ejemplo, si el ciclo fiscal varía), los residuos mostrarán autocorrelación estacional no capturada.

💡 *Buena práctica: combinar el pronóstico del SARIMA con análisis fundamental (decisiones del Banxico, inflación, datos macroeconómicos) y ajustar el tamaño de la posición en función de la amplitud del intervalo de predicción — a mayor incertidumbre (intervalo más amplio), menor posición.*